



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA



ADE
Facultad de Administración
y Dirección de Empresas /UPV

UNIVERSITAT POLITÈCNICA DE VALÈNCIA

Escuela Técnica Superior de Informática

Facultad de Administración y Dirección de Empresas

DESARROLLO DE ESTRATEGIAS DE INVERSIÓN
MEDIANTE APRENDIZAJE AUTOMÁTICO:
ANÁLISIS MULTIFACTORIAL Y EXPLORACIÓN DE
LA EFICIENCIA DE MERCADO

Trabajo Fin de Grado Integrado

Grado en Ingeniería Informática

Grado en Administración y Dirección de Empresas

AUTOR: Ignacio Bernardo Muñoz Felder

Tutor: José Alberto Sanchis Navarro

Tutor: Ismael Moya Clemente

CURSO ACADÉMICO: 2024/2025

Agradecimientos

A mis hermanos Adrián y Nicolás, por sus consejos y apoyo incondicional.

Resumen

Este trabajo explora la posibilidad de generar *outperformance* mediante el uso de modelos de aprendizaje automático aplicados a la selección de acciones. En particular, se evalúa el desempeño de tres enfoques: Ridge Classifier, XGBoost y una red neuronal profunda (DNN), en la tarea de clasificar empresas del índice S&P 500 según su retorno futuro a un año. El objetivo es construir carteras formadas por las 20 compañías con mayor probabilidad estimada de pertenecer a la clase de máximo retorno, definida como el percentil 80 dentro de cada ventana de predicción. La metodología implementa un *pipeline* de machine learning que parte de la construcción de datos históricos en formato panel, lo que plantea desafíos específicos relacionados con la variabilidad de los constituyentes a lo largo del tiempo y la necesidad de esquemas de validación temporal que eviten fugas de información (*data leakage*). Las variables predictoras se seleccionan y derivan a partir de la literatura sobre factores de inversión y estrategias con respaldo empírico. Los datos utilizados provienen de dos proveedores reconocidos: LSEG y Nasdaq Data Link. Los resultados muestran que los tres modelos superan sistemáticamente el rendimiento del índice S&P 500, posicionando a las redes neuronales profundas como el mejor modelo con un retorno anual compuesto del 16.79% durante la ventana de prueba (2004 - 2025), aunque esta mejora en rentabilidad se logra a costa de una mayor exposición a la volatilidad.

Palabras clave: outperformance, Ridge, XGBoost, DNN, data leakage, S&P500

Abstract

This study explores the potential for generating outperformance through the use of machine learning models applied to stock selection. Specifically, it evaluates the performance of three approaches, Ridge Classifier, XGBoost, and a deep neural network (DNN) in classifying S&P 500 companies based on their future one-year returns. The objective is to construct portfolios composed of the 20 companies with the highest estimated probability of belonging to the top-return class, defined as the 80th percentile within each prediction window. The methodology implements a machine learning pipeline that begins with the construction of historical panel data, which presents specific challenges related to the dynamic nature of index constituents over time and the design of validation schemes that prevent information leakage (*data leakage*). Predictor variables are selected and engineered based on investment factor literature and empirically validated strategies. The data used in this study were obtained from two reputable sources: LSEG and Nasdaq Data Link. Results show that all three models consistently outperform the S&P 500 index, with deep neural networks emerging as the best-performing model, achieving a compound annual return of 16.79% during the testing window (2004 - 2025). However, this improvement in profitability comes at the cost of higher exposure to volatility.

Keywords: outperformance, Ridge, XGBoost, DNN, data leakage, S&P500

Tabla de Contenidos

1.	Introducción.....	11
1.1.	Contexto.....	11
1.2.	Motivación.....	13
1.3.	Objetivos.....	13
1.4.	Impacto Esperado	14
1.5.	Metodología.....	16
2.	Estado del Arte	17
2.1.	Inversión Activa y Pasiva.....	17
2.2.	S&P500 como referencia de Mercado	19
2.3.	Predecir Retornos.....	19
2.4.	Introducción al Outperformance.....	20
2.5.	Teoría de Factores	21
2.6.	ML aplicado a Outperformance.....	22
2.7.	Introducción de Modelos.....	23
2.7.1.	Clasificador Ridge.....	24
2.7.2.	XGBoost.....	24
2.7.3.	Redes Neuronales Profundas	26
2.8.	Métricas de Evaluación	27
2.9.	Crítica al estado del Arte:	30
2.10.	Propuesta.....	32
3.	Selección de Variables y Proveedor.....	33
3.1.	Introducción	33
3.2.	Value	33
3.3.	Quality	34
3.4.	Growth.....	36
3.5.	Momentum	37
3.6.	Estrategias técnicas	38
3.7.	Esfuerzos inversores.....	39
3.8.	Tamaño.....	39
3.9.	Otros Indicadores	40
3.10.	Selección del Proveedor.....	41
3.11.	Conclusiones.....	43
4.	Análisis del Problema.....	44
4.1.	Introducción	44

4.2.	Definición formal del Problema	44
4.3.	Requisitos Funcionales y no Funcionales	45
4.3.1.	Requisitos Funcionales.....	45
4.3.2.	Requisitos No Funcionales	45
4.4.	Análisis del Marco Legal y Ético.....	46
4.4.1.	Marco Legal	46
4.4.2.	Marco Ético.....	47
4.5.	Análisis de Riesgos	47
4.5.1.	Máximo Drawdown	47
4.5.2.	Look-ahead bias.....	48
4.5.3.	Overfitting	48
4.6.	Identificación de Posibles Experimentos	49
4.7.	Solución Propuesta y Arquitectura.....	51
4.8.	Plan de Trabajo.....	53
4.8.1.	Estimación de Esfuerzos:	53
4.8.2.	Presupuesto	54
4.9.	Tecnologías y Herramientas.....	54
4.9.1.	Entorno de desarrollo.....	54
4.9.2.	Herramientas complementarias.....	55
4.9.3.	Principales Librerías.....	55
4.10.	Conclusiones.....	56
5.	Creación del dataset	57
5.1.	Introducción	57
5.2.	Ingestión de datos	57
5.3.	Unificación	61
5.4.	Creación de Variable Retorno	62
5.5.	Limpieza	62
5.6.	Descripción del dataset	65
5.7.	Feature Engineering.....	67
5.8.	Dataset Final.....	69
5.9.	Conclusiones.....	71
6.	Entrenamiento y Validación de Modelos	72
6.1.	Introducción	72
6.2.	Esquema de Validación	72
6.3.	Esquema de Evaluación.....	73

6.4.	Estandarización	75
6.5.	Construcción de Modelos	76
6.5.1.	Ridge Classifier	76
6.5.2.	XGBoost.....	76
6.5.3.	DNN.....	78
7.	Evaluación de Modelos	80
7.1.	Introducción	80
7.2.	Evaluación de Clasificadores	81
7.3.	Evaluación de Carteras	85
7.4.	Conclusiones de Evaluación	87
8.	Conclusiones	88
8.1.	Reflexiones Finales.....	88
8.2.	Implicaciones sobre la Eficiencia de Mercado	89
8.3.	Trabajos Futuros	90
8.4.	Relación del Trabajo con los Estudios Cursados.....	90
9.	Bibliografía.....	92
10.	Anexo	94

Glosario de Términos

- **ML:** *Machine Learning* o Aprendizaje automático, es una rama de la Inteligencia Artificial que se centra en desarrollar algoritmos que permiten a sistemas informáticos aprender de datos sin ser específicamente programados para una tarea.
- **Hedge Fund:** Popularmente conocido en castellano como Fondo de cobertura, es un tipo de fondo de inversión que busca maximizar las ganancias, independientemente de la dirección del mercado, incluso en situaciones de mercado a la baja, contando con mayor flexibilidad regulatoria.
- **IDE:** Aplicación software que provee de herramientas comprensivas para el desarrollo software.
- **ETF:** De sus siglas en inglés (*Exchange Traded Fund*), son fondos de inversión que replican el comportamiento de un cierto índice, producto o temática de inversión.
- **Benchmark:** En bolsa, un *benchmark* (o índice de referencia) es un punto de referencia utilizado para medir el rendimiento de una inversión, como un fondo de inversión o una cartera de acciones.
- **SMA:** De sus siglas en inglés (*Simple Moving Average*), representa la media móvil de la cotización de un activo.
- **CNMV:** Comisión Nacional de Mercados de Valores. Es el organismo encargado de la supervisión e inspección de los mercados de valores en España.
- **Web-Scraping:** Proceso automatizado de extracción de información a través del uso de *bots* o *scripts* sobre el código HTML de páginas web.
- **DNN:** De sus siglas en inglés (*Deep Neural Network*) es un tipo de red neuronal artificial compuesta por múltiples capas ocultas entre la capa de entrada y la de salida.
- **CAGR:** De sus siglas en inglés (*Compound Annual Growth Rate*) es la tasa de crecimiento anual compuesta. Indica el ritmo al que habría crecido una inversión si hubiese aumentado a una tasa constante cada año, desde el valor inicial hasta el valor final, durante un período determinado.

Convenciones

Con el fin de facilitar el seguimiento por parte del lector. Se han decidido las siguientes convenciones

- Se empleará *snippets* con tipografía consolas para el código fuente o nombres de variables, funciones o elementos usados en el código.
- Palabras extranjeras, términos específicos o variables de ecuaciones serán remarcadas en *cursiva*.
- Las citas textuales por otros autores serán ilustradas “entre comillas”
- La primera vez que aparezca un término disponible en el glosario de términos será remarcado con un asterisco *.

Índice de Figuras

Figura 1: División Integrada de la Memoria.....	10
Figura 2:Estructura secuencia de XGBoost.....	25
Figura 3: Estructura de una DNN	26
Figura 4: Evolución Histórica de Precio y Beneficio por acción de AutoZone Inc.	31
Figura 5: Evolución del S&P500 y su P/E.....	34
Figura 6: Outperformance de empresas lideradas por fundadores	35
Figura 7: Distribución de Beneficios	36
Figura 8: Crossover de SMA.....	38
Figura 9: Concentración de Capitalización Bursátil en el Top 5 empresas	40
Figura 10: Proveedores empleados	43
Figura 11: Constituyentes dinámicos.....	48
Figura 12: Arquitectura del Pipeline de Datos y Modelado.....	52
Figura 13: Diagrama de Valores Faltantes	63
Figura 14: Función de Densidad de Retornos a 12 meses	65
Figura 15: Matriz de Correlaciones.....	66
Figura 16: Rangos de Retorno futuro por Clase y Año	69
Figura 17: Esquema de Validación - Ventana Expansiva	73
Figura 18: Esquema de Test - Ventana Expansiva	74
Figura 19: Diversificación óptima	74
Figura 20: Accuracy por Año (ventana de predicción)	81
Figura 21: Precisión por Año (Ventana de Predicción)	82
Figura 22: Matriz de Confusión - Ridge	84
Figura 23: Matriz de Confusión - DNN	84
Figura 24: Matriz de Confusión - XGBoost	84
Figura 25: Retorno Acumulado por Modelo vs. S&P500	85

Índice de Tablas

Tabla 1: Comparación de Sharpe-ratios	30
Tabla 2: Columnas extraídas de SF1.....	59
Tabla 3: Variables de Dataset Base.....	69
Tabla 4: Comparación de Carteras	86
Tabla 5: Retornos ajustados y Outperformance.....	86

Estructura

Dada la dualidad de un Trabajo fin de Grado Integrado, y con el fin de facilitar la lectura a continuación se expone la división de los contenidos de la siguiente forma. Donde “Integrado” supone contenido relevante para ambas disciplinas. Cabe mencionar que la lectura completa es aconsejada para una comprensión total del trabajo.




Figura 1: División Integrada de la Memoria

1. Introducción

1.1. Contexto

La inversión en activos es un área del comportamiento económico humano que se remonta a periodos antiguos. Ya en el siglo XVII, en imperios como el español, holandés o británico era habitual la interacción entre diversos agentes, con el fin de proveer financiación para descubrir o explotar nuevas rutas marítimas de comercio. Para el dueño del capital, la inversión consiste en posponer el consumo actual de bienes por la esperanza de un mayor o igual poder adquisitivo en el futuro. Dada la naturaleza humana, así como sus necesidades y aversión al riesgo, la variedad de activos disponibles donde invertir capital es amplia y cada vez mayor. Según MSCI, el total de activos invertibles en 2023 alcanzaba la cifra de \$213 trillones de dólares [1].

A la hora de invertir, los activos suelen agruparse en clases que permiten analizar sus riesgos, retornos y comportamientos bajo diferentes escenarios económicos. Tradicionalmente, estas clases incluyen acciones, bonos, efectivo, bienes raíces y materias primas, aunque en los últimos años han surgido alternativas como criptomonedas, derivados y fondos de cobertura [2].

Desde una perspectiva cuantitativa, el valor de los activos inmobiliarios domina el panorama global, seguido por el mercado de deuda y, en tercer lugar, el mercado accionario [3]. Si bien las acciones no son la clase de activo más grande en volumen, su relevancia es indiscutible: destacan por su liquidez, transparencia, diversificación y, sobre todo, por su potencial de retorno. De hecho, históricamente el mercado de acciones, y en particular el S&P 500 ha sido el vehículo de inversión que ha ofrecido los mayores rendimientos a largo plazo (6.7% desde 1928), superando ampliamente a otros instrumentos tradicionales [4].

Además, dadas las políticas económicas fiduciarias modernas, la inflación, si bien moderada, es incentivada. Ocasionando pérdidas constantes de poder adquisitivo. Las acciones, que en última esencia representan participación subyacente en empresas, cuentan, de forma generalizada, con la capacidad de soportar el efecto inflacionario. A medida que los costes y salarios de empresas se incrementan, las empresas son capaces de trasladar dichos incrementos al consumidor, mediante precios unitarios mayores o bien combatiendo la inflación, por medio de innovaciones tecnológicas continuas y disciplina de costes, al ser estos, en muchos casos, deflacionarios. Estas son cualidades que otras clases de activos como el dinero o renta fija no poseen.

En este marco se establece el presente trabajo, que toma como alternativa de inversión más accesible el índice S&P500, compuesto por las 500 empresas cotizadas más relevantes de Estados Unidos. Así pues, se pretende explorar la posibilidad de generar retornos superiores a este índice.

Encontrar ineficiencias que reflejen discrepancias entre valor y precio es un proceso exhaustivo que requiere de un análisis profundo. La capacidad analítica del inversor se ve limitada y herramientas capaces de procesar grandes cantidades de datos y generar modelos de predicción se presentan como una opción interesante y con gran potencial. En este contexto surge la posibilidad de aplicar técnicas de *Machine Learning* (ML) en los mercados capitales. Según Tom M. Mitchell, [5], «Se dice que un programa de ordenador aprende de la experiencia E respecto a alguna clase de tareas T y una medida de rendimiento P , si su rendimiento en tareas de T , medido por P , mejora con la experiencia E ». Adicionalmente, Arthur L. Samuel [6] añade: «*Machine Learning* es el campo de estudio que otorga a los ordenadores la capacidad de aprender sin ser programados explícitamente».

Este conjunto de técnicas que conforman el término ML, ya han sido efectivamente desplegadas en la inversión activa. Hoy en día, se conoce como trading cuantitativo al conjunto de estrategias de inversión que utilizan modelos matemáticos y estadísticos para analizar datos de mercado y tomar decisiones de *trading*. En vez de basar los patrones de compra y venta en la opinión o intuición personal, el trading cuantitativo utiliza algoritmos y sistemas informáticos para identificar oportunidades de inversión.

Uno de los precursores del *trading* cuantitativo es Jim Simons, con su *Hedge Fund** “Medallion Fund”, cuyo fondo de inversión obtuvo la impresionante rentabilidad media del 37% anual, neta de comisiones, entre 1988 y 2021 [5]. Matemático de profesión, Jim Simons decidió focalizar su atención por completo en sus modelos estadísticos, a menudo ignorando juicios humanos o siquiera intentando comprender el razonamiento detrás de las decisiones propuestas por sus modelos. “Más de la mitad de las señales que usábamos eran contraintuitivas; si pasaban los filtros estadísticos, las operábamos» - Jim Simons citado por Zuckerman [7].

Sin embargo, existe también la otra cara de la moneda. En varias ocasiones Jim Simons ha cancelado decisiones propuestas por los modelos. Por ejemplo, en 2018 en contra de las recomendaciones de los algoritmos optó por realizar ventas masivas. Es importante recordar, que los mercados no dejan de reflejar el comportamiento de agentes, que dada su naturaleza humana, muestran comportamientos dinámicos y no estacionarios. La estructura de dicho mercado (regulación, comisiones, geopolítica, aparición de participantes, etc.) es variable y estrategias que funcionaban sin razonamiento lógico alguno, pueden dejar de hacerlo. Adicionalmente, es común que dichos algoritmos tiendan a realizar el denominado “*overfitting*”, que ocurre cuando un modelo ajusta demasiado sus parámetros a los datos de entrenamiento, incluyendo ruido o anomalías como señales, y por tanto no generalizando bien a nuevos datos.

En el presente trabajo, se opta por el segundo aproximamiento. Explorando en un primer lugar la literatura respecto la generación de retornos en renta variable. Considerando diversos estudios sobre factores y su puesta en práctica por inversores. Además, se plantea una visión propia en el desarrollo de algoritmos, pero construyendo sobre

estudios previos en la misma disciplina. Esto acelera la elección de técnicas, parámetros, ventanas, esquemas temporales y datos.

El objetivo es la identificación de acciones con rendimientos superiores a la media del mercado. En concreto, se discute y analiza la implementación de 3 técnicas de modelado frente al problema planteado. Un modelo lineal Ridge de clasificación frecuentemente usado por su simplicidad y rapidez, un modelo XGBoost basado en arboles de decisión que facilita la interpretación y un modelo de redes neuronales profundas, escogido por su gran potencia y capacidad no lineal. Sobre estos modelos se construirán carteras en base a las clasificaciones realizadas sobre un conjunto temporal de Test. Por último, dichas carteras serán evaluadas en base a sus resultados mediante matrices de confusión, rendimientos, volatilidad y otras métricas relevantes para el inversor.

1.2. Motivación

Este trabajo supone la intersección entre mi curiosidad personal y ambas disciplinas estudiadas estos últimos 5 años, la Informática y la Administración y Dirección de Empresas. Mi interés por los mercados no es una novedad. Como antiguo *Head of Investments* del UPV Investment Club he tenido la suerte de poder formar parte de una asociación de estudiantes cuya pasión por los mercados capitales es compartida. Mi fascinación por la tecnología y la creciente proliferación de sistemas inteligentes es altamente aplicable en estos campos. Tras mi humilde y corta experiencia operando en los mercados, reconozco la dificultad psicológica de mantenerse fiel a estrategias de inversión. Los mercados son altamente emocionales y ponen a prueba la capacidad del inversor en cada ciclo. Las máquinas en contraste no padecen de esta debilidad. Con este trabajo pretendo alimentar mi conocimiento sobre la magnitud de la oportunidad que ofrecen sistemas inteligentes al proceso inversor, así como ganar las habilidades necesarias para considerarlo como una posible salida profesional.

1.3. Objetivos

De forma general, este trabajo tiene como objetivo desarrollar y validar estrategias de inversión en acciones, basadas en modelos de ML, que generen retornos superiores a los índices S&P500. Como se ha mencionado previamente, este trabajo supone la integración de conceptos en las disciplinas de Finanzas y Ciencia de Datos. Por ello se ha considerado relevante dividir el anterior objetivo en 2 partes.

OG-1: Interpretar los fundamentos teóricos y estrategias de inversión sobre los que extraer variables claves con capacidad predictiva para entrenar los algoritmos.

OG-2: Abordar el desarrollo técnico de algoritmos supervisados de clasificación según la predicción de rendimiento superior al mercado.

Adicionalmente, el trabajo pretende abordar una serie de objetivos específicos mencionados a continuación.

- ❖ 1. Describir el contexto necesario al que se enfrenta el inversor, alternativas y ventajas de cada tipo de gestión.
- ❖ 2. Demostrar la capacidad del ML en la inversión y su implementación actual en la construcción de carteras inteligentes.
- ❖ 3. Definir de forma precisa el problema a intentar optimizar mediante ML por parte del inversor.
- ❖ 4. Construir un *dataset* histórico anual sobre empresas constituyentes del SP500.
- ❖ 5. Diseñar un Pipeline software que descargue, normalice y almacene los datos sobre el universo.
- ❖ 6. Evaluar la existencia de rendimientos superiores al índice en portafolios cuya elección de posiciones ha sido basada según algoritmos supervisados de clasificación.
- ❖ 7. Comparar diversos algoritmos de ML según su capacidad de predecir *outperformance* (rendimientos superiores al mercado)
- ❖ 8. Discutir la implementación y optimización de dichos algoritmos mediante la creación de carteras de inversión optimizadas.

1.4. Impacto Esperado

A primera vista, el desarrollo de mejores y más avanzadas técnicas de inversión mediante ML tienen como impacto esperado, el de posibles ganancias económicas derivadas de su uso por parte de aquellas organizaciones o individuos que las desarrollan. Para los analistas financieros, suponen un ahorro de tiempo al acelerar el cribado de señales predictivas.

Más allá del lucro económico que estos pueden derivar, el desarrollo de modelos más eficientes permite entender mejor los mercados capitales. Al identificar posibles ineficiencias y explotarlas, dichos modelos hacen del mercado un lugar más eficiente donde el capital se reparte correctamente entre los agentes que lo demandan para sus proyectos, contribuyendo así al desarrollo de la economía y evolución tecnológica.

En caso de que los modelos no consigan batir los resultados de una cartera indexada, el trabajo aporta información al inversor sobre la complejidad de la tarea, que puede llegar a ser solo realizable mediante una mayor infraestructura, capacidad de cómputo y datos, que los empleados en este trabajo. Si ese fuera el caso, este descubrimiento proveería al inversor particular la tranquilidad de que indexarse pueda ser de hecho la mejor opción disponible dados sus recursos.

En relación con los Objetivos de Desarrollo Sostenible (ODS), este trabajo pretende fomentar la innovación en la industria de gestión de activos, democratizando el acceso a herramientas de análisis avanzado y reduciendo por tanto la brecha entre grandes instituciones y pequeños inversores. En 2015, los líderes mundiales adoptaron un conjunto de objetivos globales para erradicar la pobreza, proteger el planeta y asegurar la prosperidad para todos como parte de una nueva agenda de desarrollo sostenible. Entre estos objetivos el trabajo se relaciona con:

- **Fin de la pobreza (ODS-1):** el ahorro e inversión en mercados de capitales libres, temática en la que se basa este proyecto, son receta que ha servido en el pasado, y servirá en el futuro para acabar con la pobreza. Adicionalmente la integración de sistemas inteligentes en la inversión ofrece infinitud de posibilidades para individuos, empresas e incluso en gobiernos, mejorando los objetivos de fondos soberanos como el suizo o el noruego. En resumen, acabar con la pobreza está estrechamente relacionado con el ahorro, la inversión y la posibilidad de hacerlo de forma libre.
- **Educación de calidad (ODS-4):** el presente trabajo promueve el acceso a fuentes de información de calidad, como se ha demostrado accediendo a bases de datos profesionales, También busca crear conocimiento excepcional a través del análisis concienzudo y detallado. Es por ello que considero que este proyecto cumple con el objetivo de fomentar la educación de calidad.
- **Trabajo decente y crecimiento económico (ODS-8):** El presente trabajo promueve la profesión de analistas de mercado e inversores. Una profesión que de forma común no es entendida en amplios sectores de la sociedad, pero que realmente aporta un valor añadido a través de la distribución eficiente de recursos. Esta eficiencia es la que acaba produciendo el crecimiento económico, del que finalmente la sociedad en su conjunto se beneficia.

Más información referente a la adecuación del trabajo frente al resto de ODS puede ser encontrada en los Anexos.

1.5. Metodología

El trabajo emplea dos metodologías de forma consecutiva con el fin de estructurar el desarrollo del modelo correctamente y aumentar la capacidad predictiva del resultado final. Cada una de las metodologías se aferra al cumplimiento de cada objetivo general descrito en la Sección 1.3 Objetivos.

Metodología 1. Selección de Factores

1. Comprensión del Problema que se busca optimizar. En esta Sección hacemos una introducción a la predicción de retornos mediante ML, proveemos el contexto ¿Qué supone predecir retornos? Focalizando así nuestro estudio hacia ciertas áreas específicas
2. Revisión Bibliográfica y estudio sobre estrategias tradicionales de inversión
3. Técnicas de selección de variables clave que parecen tener cierto éxito en predecir *outperformance*
4. Propuesta sobre variables elegidas
5. Análisis y selección del proveedor capaz de ofrecer dichas variables

Metodología 2: “ML Pipeline”

El pipeline de ML se refiere a la cadena de procesos automatizados y reproducibles que llevan a unos datos crudos hasta un modelo entrenado y validado. Aunque existen diversas variantes que enfatizan más ciertas partes del desarrollo, en este caso nos centraremos en los siguientes procesos:

1. Extracción de Datos. También conocido como *Data Ingestion*
 - Realizar conexión a fuente de datos mediante API
 - Extracción de datos
 - Almacenamiento estructurado (datos tabulados) y persistente (.csv)
2. Limpieza y preprocesado
 - Tratar valores faltantes (Imputación)
 - Eliminación de columnas duplicadas
3. Ingeniería de Características. También conocido como *Feature Engineering*
 - Creación de nuevas variables
 - Escalado, estandarización y codificación de variables categóricas
 - Creación de variable objetivo
4. Selección Final de Variables
5. Partición del conjunto de datos adaptado al formato panel
6. Entrenamiento y ajuste de modelos: Proceso iterativo de prueba y error que involucra a su vez la validación de hiperparámetros
7. Evaluación y Presentación de Resultados

2. Estado del Arte

Generar rendimientos superiores al mercado ha sido un objetivo central en la gestión activa de inversiones. Este capítulo introduce los conceptos clave relacionados con la inversión activa y pasiva, y plantea cómo se define y mide el rendimiento relativo frente a un índice de referencia.

A continuación, se revisan distintas explicaciones sobre la obtención de rentabilidad extra, incluyendo modelos clásicos de valoración, estrategias basadas en factores y otros enfoques cuantitativos. También se exploran nuevas aproximaciones basadas en técnicas de aprendizaje automático, que permiten identificar patrones complejos en los datos históricos.

El capítulo concluye con una propuesta experimental que evalúa modelos de clasificación para construir carteras, incorporando métricas de evaluación para analizar el comportamiento de los modelos con datos no usados en el entrenamiento. Este planteamiento permite analizar el grado con el que es posible identificar de forma sistemática qué activos ofrecerán un mejor comportamiento futuro.

2.1. Inversión Activa y Pasiva

De forma general, existen dos aproximaciones principales a la inversión en acciones: la inversión activa y la inversión pasiva.

La inversión pasiva busca replicar el comportamiento de un índice de referencia, como el S&P 500, MSCI World o STOXX Europe 600. Esta estrategia parte de la hipótesis de que los mercados financieros son mayormente eficientes, lo que implica que resulta extremadamente difícil y costoso, obtener rendimientos consistentemente superiores al promedio del mercado. Por tanto, para la mayoría de inversores, la mejor opción suele ser exponerse de forma diversificada a todo el mercado a través de vehículos como los fondos indexados o los ETFs* (Exchange Traded Funds) [8]. La inversión pasiva ha ganado una gran popularidad en las últimas décadas debido a sus claras ventajas frente a la gestión activa. Productos como los fondos indexados y ETFs han democratizado el acceso a los mercados financieros, ofreciendo bajos costes, alta transparencia, gran liquidez y diversificación automática, lo que los convierte en una opción especialmente atractiva para inversores particulares y profesionales por igual.

En contraste, la inversión activa implica la búsqueda constante de acciones individuales cuyo futuro retorno se espera sea superior al resto del mercado. Mediante la construcción de una cartera compuesta por varias de estas oportunidades, el inversor activo trata de superar el rendimiento del índice de referencia. Esta aproximación requiere un análisis

exhaustivo, selección de valores, gestión dinámica, y asume mayores costes de transacción, comisiones y, en muchos casos, una mayor volatilidad de resultados. La base teórica de la inversión activa radica en la creencia de que el mercado no es perfectamente eficiente y que existen ineficiencias temporales o estructurales (por ejemplo, errores de valoración, reacciones excesivas o lentitud en la incorporación de nueva información) que pueden ser aprovechadas para obtener rendimientos superiores al mercado ajustados por su riesgo (es decir, generar *alpha*) [9].

Numerosos estudios académicos y reportes del sector financiero han demostrado que la mayoría de los gestores activos no logran batir de forma consistente a los índices, especialmente después de descontar comisiones y gastos de gestión. Por ejemplo, según el informe anual de SPIVA de 2023, más del 85% de los fondos de gestión activa en Estados Unidos quedaron por detrás del S&P 500 en periodos de 10 y 15 años [10].

Este fenómeno se ha observado en mercados desarrollados y emergentes, así como en diferentes clases de activos, reforzando la idea de que “el mercado” suele ser difícil de superar de manera persistente. No obstante, la inversión activa sigue teniendo defensores y un papel relevante en la gestión patrimonial. Las posibles recompensas para quienes logran *outperformance* son elevadas, y gracias al interés compuesto mínimas diferencias de rentabilidad anual pueden generar diferencias masivas. Por ejemplo, un individuo que invirtiese 10,000 € durante 30 años al retorno histórico del S&P 500 (6.7% anual) obtendría 74,217 €. Si en cambio consiguiera un *outperformance* sostenido del 2% anual (retorno total del 8.7% anual), alcanzaría casi el doble: 134,716 €.

En resumen, la literatura y los datos empíricos respaldan la idea de que la inversión pasiva suele ser la mejor opción para la mayoría de los inversores a largo plazo. Sin embargo, la existencia de estrategias activas ganadoras, aunque poco frecuentes, motiva la investigación en nuevos enfoques, como el uso de aprendizaje automático para detectar patrones y anomalías que puedan generar rendimientos superiores a los del mercado.

En los últimos años, la proliferación de algoritmos y el desarrollo de nuevas técnicas de aprendizaje automático han generado un enfoque intermedio entre la gestión activa y la pasiva. Conocidos como *Smart-portfolios* o carteras inteligentes, estas estrategias semi-pasivas seleccionan activos que cumplen una serie de filtros o factores cuantitativos históricamente asociados a la obtención de mayores retornos ajustados al riesgo, como valor, calidad, *momentum* o baja volatilidad [11]. Estos enfoques automatizados permiten a los gestores diseñar carteras que se benefician de reglas sistemáticas basadas en datos, reduciendo el sesgo humano y los costes de transacción asociados a la selección manual, pero manteniendo la posibilidad de obtener rendimientos superiores a una simple réplica del índice.

Así, la frontera entre gestión activa y pasiva se difumina, dando lugar a estrategias híbridas que buscan combinar lo mejor de ambos mundos: la eficiencia, simplicidad y bajo coste de la indexación con la capacidad de capturar primas de riesgo adicionales a través de criterios cuantitativos y modelos predictivos avanzados.

2.2. S&P500 como referencia de Mercado

Como se ha mencionado previamente, los gestores comparan sus rendimientos frente a los de un índice de referencia, conocido como *benchmark**. Esto facilita a los partícipes evaluar la capacidad de los fondos de inversión en superar a una cartera pasiva que replique dicho índice, y por tanto el grado de justificación de las comisiones del fondo.

El S&P500 (Standard & Poor's 500) es un índice bursátil frecuentemente usado como *benchmark*. Este está compuesto por las 500 empresas de mayor capitalización bursátil en Estados Unidos. Dada la gran importancia de la economía estadounidense sobre el conjunto global, el S&P500 es reconocido como una medida de rendimiento de renta variable. Creado en 1957 por Standard & Poor's, incluye empresas como Apple, Microsoft o Tesla, abarcando el 80% de la capitalización de mercado total en los Estados Unidos.

El S&P500 es considerado un *benchmark* ideal por varias razones:

- Alta diversificación sectorial.
- Alta liquidez dado que sus componentes son diariamente intercambiados.
- Transparencia y replicabilidad: Cuenta con un gran conjunto de productos indexados (*ETF's*) que replican fielmente su comportamiento, así como información disponible que facilita el análisis de sus componentes.

Además, otro hecho interesante es su carácter dinámico, dado que se compone de empresas a las cuales nos referiremos como constituyentes. Cuando una empresa deja de pertenecer al conjunto de 500 empresas más relevantes, el índice deja de replicar su comportamiento y añade un nuevo constituyente.

2.3. Predecir Retornos

La noción de Valor Actual Neto (VAN) definida en la Ecuación (1) establece que el valor de una empresa equivale al valor de los flujos de caja futuros esperados, descontados a valor presente, menos la inversión inicial requerida.

$$VAN = \sum_{t=1}^n \frac{F_t}{(1+k)^t} - I_0 \quad (1)$$

En este sentido, los precios de las acciones, que representan participaciones en dichas empresas, reflejan las expectativas colectivas del mercado sobre dichos flujos futuros. Los retornos de una acción corresponden a los cambios en su precio a lo largo del tiempo, lo cual implica, en última instancia, cambios en las expectativas sobre los flujos de caja futuros de la empresa.

Predecir retornos consiste, por tanto, en anticipar cómo y cuándo varían estas expectativas de mercado. Es habitual utilizar la evolución de los flujos de caja históricos para analizar la trayectoria financiera de la empresa y, junto a otras variables relevantes, construir estimaciones sobre sus resultados futuros. Estas predicciones, descontadas a valor presente, proporcionan la mejor aproximación al valor intrínseco de la empresa en cada momento.

2.4. Introducción al Outperformance

En la disciplina de gestión patrimonial, el *Outperformance* se refiere a inversiones, carteras o gestores que muestran un rendimiento superior al mercado. En este contexto, se entiende el mercado como la cesta amplia de productos directamente comparables en términos de riesgo, rentabilidad y clase de activo.

La Teoría de los Mercados eficientes [12] postula que, en su nivel de eficiencia más fuerte, los precios de los activos reflejan toda la información disponible de forma rápida y sin sesgos sistemáticos. La derivación lógica establecida en la literatura, por tanto, es que la única fuente de rentabilidad adicional es la prima recibida por asumir mayor riesgo. En concreto, el tipo de riesgo no eliminable, incluso tras una correcta diversificación de la cartera, es decir el riesgo sistemático.

Esta intuición se ve reflejada en uno de los pilares fundamentales de la valoración de activos, el CAPM (Capital Asset Pricing Model), inicialmente presentado por Sharpe [13] y refinado por Linter [14] y Mossin [15]. Este modelo propone un aproximamiento al cálculo del rendimiento sobre activos individuales, sugiriendo que este se encuentra linealmente relacionado con la rentabilidad media del mercado. De esta forma, el rendimiento esperado de un activo, calculado según la Ecuación (2) se deriva como la tasa libre de riesgo (R_f) más la prima de mercado ($E(R_m) - R_f$) ajustada por la sensibilidad al mercado (β). Dicha sensibilidad (β) mide la volatilidad o riesgo sistemático de una acción con relación al mercado.

$$E(R_i) = R_f + \beta_i * (E(R_m) - R_f) \quad (2)$$

Posteriormente, Jensen en 1968, [9] conceptualizó el *alpha*, definido como la rentabilidad adicional obtenida por un activo o cartera, que no puede ser explicada por su nivel de exposición al riesgo sistemático del mercado. Esto es, dado el retorno de la Cartera (R_p), *alpha* se calcula como:

$$Alpha = R_p - [R_f + \beta(R_m - R_f)] \quad (3)$$

Otro concepto, también ideado por W. Sharpe en 1966, fue el *sharpe-ratio*. Como es lógico, los inversores no solo demandan rendimientos satisfactorios, sino una volatilidad adecuada a sus necesidades de liquidez y estabilidad [16].

Por ello de forma común, los fondos de inversión son comparados en términos de retornos ajustados por riesgo σ (volatilidad) . Esto es precisamente lo que refleja el *sharpe-ratio* en la Ecuación (4). En esencia, permite a los inversores conocer cuanto retorno en exceso se obtiene por el riesgo que toman en una inversión. Siendo R_e el retorno que se espera del fondo.

$$Sr = \frac{E[R_e - R_f]}{\sigma} \quad (4)$$

2.5. Teoría de Factores

Sin embargo, la evidencia empírica muestra que es posible seleccionar activos que superan sistemáticamente al mercado, incluso después de ajustar por beta (β) o volatilidad (σ). Esto sugiere que existen otras fuentes de riesgo o retorno que el CAPM no captura. Para explicar estas anomalías, en 1993 surgen los modelos multifactoriales, destacando el modelo de tres factores de Fama y French. Además del factor de mercado, identifican dos primas sistemáticas adicionales [17] [18]:

- **SMB** (*Small Minus Big*): recoge la tendencia de las empresas de pequeña capitalización a superar a las grandes.
- **HML** (*High Minus Low*): refleja la mayor rentabilidad de las empresas con alta relación valor contable/precio (*value*) frente a las de baja relación (*growth*).

Este modelo mostró que muchos *alphas* identificados con CAPM desaparecen al controlar por estos dos riesgos sistemáticos adicionales. Poco después, Carhart introduce un cuarto factor:

- **MOM** (*Momentum*): representa la persistencia en el comportamiento de los activos. Es decir, aquellos que han tenido buenos rendimientos recientes tienden a seguir haciéndolo bien a corto plazo [19].

En 2015, Fama y French amplían de nuevo su esquema, apoyados en bases de datos más completas. Mantienen el factor de mercado y SMB, pero reemplazan HML por dos nuevos factores [20]:

- **RMW** (*Robust Minus Weak*): captura la rentabilidad operativa robusta frente a la débil. Es decir empresas con altos ingresos operativos sobre patrimonio neto (EBIT/PN)
- **CMA** (*Conservative Minus Aggressive*): diferencia entre empresas con políticas de inversión conservadoras y agresivas.

Su evidencia apunta a que la importancia del factor *value* clásico disminuye cuando se incluyen RMW y CMA, reinterpretando así la naturaleza del *alpha* en muchas estrategias.

En los últimos años, la literatura financiera ha identificado aún más factores, como *quality*, *low volatility* o *liquidity*. El modelo Q-Factor [21] combina rentabilidad sobre patrimonio neto esperada (ROE), inversión y tamaño desde una óptica de economía real. Este fenómeno, conocido como el "factor zoo", refleja la proliferación de nuevos factores candidatos a explicar los rendimientos. Así, el concepto de *outperformance* se vuelve cada vez más exigente: cuantos más factores explicativos se incorporan, menor es el espacio para obtener un *alpha* genuino que no pueda explicarse por riesgos sistemáticos identificados.

2.6. ML aplicado a Outperformance

El uso de técnicas de aprendizaje automático (ML) para la predicción de retornos bursátiles ha experimentado un crecimiento significativo en la última década, gracias a la disponibilidad de poder computacional y de grandes cantidades de datos sobre los que se entrenan los modelos.

Mientras que los enfoques tradicionales de *asset pricing* se basaban en modelos, la disponibilidad de grandes volúmenes de datos financieros y el avance de las capacidades computacionales han permitido a los investigadores explorar relaciones no lineales y de alta dimensión entre características de las empresas y sus rendimientos futuros.

En uno de los trabajos más influyentes en este campo [22], se comparan múltiples métodos de aprendizaje automático para estimar las primas de riesgo esperadas de acciones individuales. Su estudio demuestra que modelos como redes neuronales profundas y *random forests* superan sistemáticamente a las regresiones lineales tradicionales en la predicción de retornos mensuales. Los autores modelan la expectativa condicional del retorno a un mes vista como una función de más de 90 características financieras y macroeconómicas, mostrando que ML puede captar interacciones complejas entre señales predictoras.

Aunque gran parte de la literatura se centra en horizontes mensuales, algunos autores han explorado ventanas más largas. Por ejemplo, Asness, Frazzini y Pedersen [23] estudian el factor *value* y el *momentum* en ventanas anuales, mostrando que muchas anomalías persisten a largo plazo.

Alternativamente, en un estudio reciente centrado específicamente en el S&P 500, se explora la rentabilidad de utilizar algoritmos de aprendizaje automático para seleccionar subconjuntos de acciones a partir de factores cuantitativos como características [24]. El trabajo utiliza algoritmos basados en árboles (*Decision Tree*, *Random Forest* y *XGBoost*) por sus capacidades explicativas (*white-box*), lo que permite analizar la importancia relativa de las variables predictoras en diferentes momentos del tiempo. A través de un sistema de *backtesting* con rebalanceo periódico, se demuestra que las carteras generadas superan al índice de referencia, aunque con mayor riesgo. Una contribución clave del estudio es mostrar cómo la importancia de los factores cambia con el tiempo, lo que ofrece información valiosa para diseñar estrategias dinámicas y explicables de inversión basada en ML.

2.7. Introducción de Modelos

En el ámbito del aprendizaje automático aplicado a finanzas, la selección del modelo es un paso fundamental que determina tanto la capacidad predictiva como la interpretabilidad de la solución. La literatura reciente muestra una clara preferencia por modelos no paramétricos o altamente flexibles, capaces de captar relaciones complejas y no lineales entre variables financieras. Este enfoque surge de la evidencia empírica de que los retornos de activos financieros no responden a relaciones simples o estáticas, sino a interacciones dinámicas y contextuales que evolucionan con el tiempo.

Los modelos no paramétricos, como los árboles de decisión o métodos basados en vecinos cercanos no imponen una forma funcional rígida entre las variables de entrada y la salida. En su lugar, aprenden directamente de los datos, adaptando su estructura a medida que se incrementa el volumen de información disponible. Esta propiedad los convierte en herramientas idóneas para capturar patrones ocultos en contextos de alta dimensionalidad, como ocurre en la predicción de retornos bursátiles. Alternativamente, los modelos paramétricos flexibles, como las redes neuronales profundas, también permiten captar relaciones complejas y no lineales, aunque requieren definir previamente su estructura.

A pesar de sus ventajas, el uso de modelos más complejos requiere contrastarlos con alternativas más sencillas y bien entendidas. Por ello, se opta por incluir también un modelo lineal como punto de comparación y línea base. Este modelo de referencia permite establecer si la complejidad adicional de los modelos avanzados se traduce efectivamente en mejoras prácticas.

A continuación, se describen brevemente los tres modelos seleccionados para este trabajo, que representan distintos enfoques dentro del aprendizaje automático:

2.7.1. Clasificador Ridge

El modelo Ridge es una forma regularizada de regresión lineal (o de clasificación lineal, en su versión Ridge Classifier) que incorpora una penalización L2 sobre los coeficientes del modelo. Esta penalización reduce la varianza, mejora la generalización y previene el sobreajuste, especialmente en contextos con alta dimensionalidad o multicolinealidad. En tareas de clasificación, Ridge busca una frontera de decisión lineal que separe las clases objetivo, en este caso, distintos niveles de retorno futuro. Su principal fortaleza radica en su simplicidad e interpretabilidad: los coeficientes pueden analizarse directamente para entender la influencia relativa de cada variable predictora. A pesar de ser un modelo lineal, Ridge ha demostrado un rendimiento competitivo en entornos financieros, particularmente cuando el conjunto de datos es limitado o presenta alto ruido, donde modelos más complejos pueden sobreajustarse fácilmente.

La regresión *ridge* busca minimizar una función de pérdida compuesta por dos términos, tal y como se puede observar en la Ecuación (5).

$$\hat{\beta} = \arg \min_{\beta} \left\{ \sum_{i=1}^n (y_i - X_i \cdot \beta)^2 + \lambda \sum_{j=1}^p \beta_j^2 \right\} \quad (5)$$

Donde

- y_i es el valor objetivo para la observación i ,
- X_i es el vector de características para la observación i ,
- β es el vector de coeficientes a estimar,
- $\sum_{j=1}^p \beta_j^2$ es la norma L2 cuadrada de los coeficientes, es decir la suma de los cuadrados de los coeficientes.
- $\lambda \geq 0$ es el hiperparámetro de regularización. En la implementación computacional mediante `scikit-learn`, el parámetro de regularización λ se denota como α , y cumple exactamente la misma función: penalizar la magnitud de los coeficientes para mejorar la generalización del modelo.

2.7.2. XGBoost

XGBoost es una implementación eficiente y optimizada del algoritmo *Gradient Boosting Decision Trees* (GBDT). Esta es una técnica de aprendizaje automático basada en árboles

de decisión que construyen un modelo fuerte a partir de la combinación secuencial de modelos débiles, habitualmente árboles poco profundos. Como se puede observar en la Figura 2, en cada iteración se entrena un nuevo árbol para corregir los errores cometidos por el conjunto de árboles anteriores, en un proceso aditivo y orientado por gradiente. Este procedimiento se repite hasta alcanzar un número de K de iteraciones o hasta minimizar la función de pérdida.




Figura 2: Estructura secuencial de XGBoost

Fuente: Song et al. (2021), "Ensemble learning for the early prediction of neonatal jaundice with genetic features."

El objetivo es la minimización de una función de pérdida $\mathcal{L}$, definida en la Ecuación (6), que combina el error de predicción con un término de regularización. Este último penaliza la complejidad del modelo. Formalmente, para una predicción $\hat{y}_i$ del ejemplo i , se tiene:

$$\mathcal{L}^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t) \quad (6)$$

Donde:

- $\mathcal{L}^{(t)}$ es una función de pérdida diferenciable (como *log-loss* o *squared error*)
- f_t es el nuevo árbol que se añade en la iteración t ,
- $\Omega(f) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2$ es un término de regularización que penaliza el número de hojas T y los pesos w_j de cada hoja, para evitar sobreajuste.

XGBoost destaca por su capacidad para modelar relaciones complejas no lineales (como las presentes en datos financieros), sin requerir ingeniería de variables manual intensiva,

además de su robustez ante sobreajuste gracias a la regularización. Adicionalmente, mantiene ventajas comunes de los árboles de decisión como la posibilidad de interpretar la importancia de cada variable. Por último, gracias a su eficiencia y paralelización, XGBoost reacciona bien a *datasets* grandes incluso con valores faltantes y no requiere normalización. En este trabajo se hace uso de la versión de clasificación de XGBoost, mediante su librería en Python, `XGBClassifier`.

2.7.3. Redes Neuronales Profundas

Una red neuronal es un modelo computacional inspirado en el funcionamiento del cerebro humano, diseñado para resolver problemas de clasificación, predicción o reconocimiento de patrones. La red se compone de nodos (neuronas) organizadas en capas, que procesan datos de entrada, identifican patrones y generan salidas útiles, como probabilidad de pertenecer a un conjunto etiquetado. Una red neuronal profunda, DNN* es un tipo de red neuronal artificial compuesta por múltiples capas ocultas entre la capa de entrada y la de salida. Cada una de estas capas oculta aprende representaciones no lineales cada vez más abstractas, esto convierte a las DNN en potentes herramientas frente a tareas con relaciones complejas entre variables.




Figura 3: Estructura de una DNN

Fuente: Lee et al. (2017)

En una DNN, cada capa cumple un rol distinto en la construcción del conocimiento del modelo. La primera capa suele aprender combinaciones simples de las variables de entrada. Las capas intermedias combinan esos patrones iniciales en estructuras más complejas. Las últimas capas capturan representaciones de alto nivel directamente útiles para la tarea, como clasificar activos según su probabilidad de buen rendimiento futuro. Este proceso permite a la red aprender representaciones progresivamente más abstractas y jerárquicas de los datos.

Matemáticamente, cada neurona aplica una función lineal, tal como se define en la Ecuación (7):

$$z = w \cdot x + b \quad (7)$$

Donde:

- w son los pesos del modelo: valores que determinan cuánta importancia tiene cada entrada
- x vector de entrada con datos
- b es el sesgo o *bias*, que permite desplazar la activación independientemente de las entradas.

Tras calcular z , se aplica una función no lineal $f(z)$ que introduce la capacidad de modelar relaciones complejas entre variables. Entre las funciones más populares destacan:

- **ReLU (*Rectified Linear Unit*)**: usada en capas ocultas por su simplicidad y eficiencia, activa solo los valores positivos y anula los negativos, tal y como se define en la Ecuación (8):

$$\text{ReLU}(z) = \max(0, z) \quad (8)$$

- **Softmax**: Usada en la capa de salida en problemas de clasificación multiclase, transforma un vector de puntuaciones (*logits*) en una distribución de probabilidades que suma 1. Cada componente representa la probabilidad de pertenecer a una clase de un conjunto de K clases posibles. La función Softmax se calcula tal y como se define en la Ecuación (9), siendo z_i el logit para la clase i .

$$\text{Softmax}(z_i) = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}} \quad \text{para } i = 1, 2, \dots, K \quad (9)$$

2.8. Métricas de Evaluación

En esta Sección se presentan una serie de métricas habitualmente empleadas en la literatura con el objetivo de evaluar la precisión de los modelos.

1. Retorno Acumulado de la Cartera

Se calcula según la Ecuación (10), donde r_t es el retorno de la cartera en el periodo t , y T es el número total de periodos. Esta métrica refleja el crecimiento total de la inversión

bajo un esquema de reinversión continua, y es clave para evaluar el rendimiento efectivo de las decisiones de asignación de activos.

$$R_{acum.} = \prod_{t=1}^T (1 + r_t) - 1 \quad (10)$$

2. Volatilidad de la Cartera:

En este caso se usa la versión simplificada para series temporales, tal y como se describe en la Ecuación (11) donde $\bar{r}$ es el retorno medio de la cartera. A pesar de la definición previa de riesgo, se considera la volatilidad como una métrica relevante para el inversor. La versión simplificada evalúa la variabilidad de los retornos anuales.

$$\sigma = \sqrt{\frac{1}{T-1} \sum_{t=1}^T (r_t - \bar{r})^2} \quad (11)$$

3. Matriz de confusión

La matriz de confusión es una herramienta fundamental para evaluar el rendimiento de modelos de clasificación. Proporciona información detallada sobre el tipo de errores cometidos. En la Ecuación (12) se puede observar un ejemplo de matriz de confusión con 5 clases. Donde i representa una observación a predecir, el primer subíndice (filas) representa la clase real, y el segundo subíndice (columnas) la clase predicha. Así pues i_{44} representa observaciones de clase 4, correctamente clasificadas como clase 4.

$$\text{Matriz de Confusión de 4 clases} = \begin{bmatrix} i_{00} & \cdots & i_{04} \\ \vdots & \ddots & \vdots \\ i_{40} & \cdots & i_{44} \end{bmatrix} \quad (12)$$

En este trabajo, cada clase representará un rango de retornos, identificándose con su posición relativa respecto al retorno medio del S&P500 medio:

0. *negative*,
1. *underperformance*,
2. *near-performance*,
3. *overperformance*,
4. *overperformance – portfolio*.

Aunque tanto la clase (3) como la clase (4) representan *outperformance* en el sentido estricto, dado que hacen referencia a rendimientos por encima de la media (siendo clase 2 rendimientos entorno a la media), en el presente trabajo nos centramos en la clase (4). Esta última clase (4) representa las empresas con los retornos más elevados y es el objetivo de predicción de los modelos. Asumiendo que se define una clase “*overperformance - portfolio*” $C \in \{c_1, c_2, \dots, c_n\}$ que corresponde al rango más alto de retornos;

Los siguientes conceptos permiten derivar métricas de acierto para clasificadores:

- **TP (C)**: instancias correctamente clasificadas como clase **C**.
- **FP (C)**: instancias de otras clases clasificadas incorrectamente como clase **C**.
- **FN (C)**: instancias de clase **C** clasificadas como otra clase.
- **TN (C)**: todas las demás instancias correctamente no clasificadas como clase **C**.

4. Precisión

Muestra la proporción de predicciones correctas respecto al total de predicciones para una clase. Es especialmente interesante para el caso que concierne este trabajo. Mediante la elaboración de una cartera, no es necesario encontrar todas las empresas con un retorno alto, sino que las empresas finalmente clasificadas en la clase de retornos más alta, no sean erróneamente clasificadas. Es decir, minimizar el número de falsos positivos (FP). Siendo TP_c el número de predicciones de la clase **C** correctamente clasificadas y FP_c el número de predicciones de la clase **c** que no pertenecen a la clase **C**, la métrica *Precision* se calcula según la ecuación (13).

$$Precision = \frac{TP_c}{TP_c + FP_c} \quad (13)$$

5. Recall

Muestra cuántos casos de la clase **C** son realmente clasificados como tal. Si bien resulta menos relevante ya que no es necesario encontrar todos los casos, sigue siendo una métrica con cierto interés. Siendo FN_c el número de muestras de la clase **C** clasificadas como otra clase, la Ecuación (14) muestra el cálculo del *Recall*.

$$Recall = \frac{TP_c}{TP_c + FN_c} \quad (14)$$

6. Accuracy

Muestra cuantas veces el modelo acertó la clase correcta, representando una medida de “precisión global” entre todas las clases. Esto indica como de preciso es el clasificador en identificar correctamente observaciones para todas las clases. *Accuracy* se calcula según la Ecuación (15).

$$Accuracy = \frac{\sum_{i=1}^n 1(y_i = \hat{y}_i)}{n} \quad (15)$$

Donde:

- y_i es la clase verdadera del ejemplo i ,
- $\hat{y}_i$ es la clase predicha para el ejemplo i ,
- 1 es la función indicadora (vale 1 si la predicción es correcta y 0 si no),
- n es el número total de ejemplos.

7. MDD

La siguiente versión de MDD o *drawdown* máximo, calculado según la Ecuación (16), mide la mayor caída año a año, o lo que es equivalente, el peor retorno anual. Resulta especialmente interesante desarrollar estrategias que no tengan años excesivamente malos ya que esto daña seriamente la confianza sobre el modelo y rompen el poder del interés compuesto.

$$\text{MDD} = \min_{t \in \{1, \dots, T\}} (R_t) \quad (16)$$

2.9. Crítica al estado del Arte:

Es importante puntualizar que Sharpe entendió la volatilidad como una medida directa del riesgo de una acción. Esta asunción es mayoritariamente consensuada en la literatura. Si bien carteras con menores varianzas son comúnmente deseadas por los inversores, el anterior aproximamiento cuenta con un sesgo a destacar.

Como se puede observar en la Tabla 1, El *sharpe-ratio* penaliza toda volatilidad, también al alza. Haciendo que a pesar del mayor rendimiento de B, la cartera A obtenga un mayor *sharpe-ratio*.

Tabla 1: Comparación de Sharpe-ratios

Cartera	A	B
t=0	100	100
t=1	105	150
t=2	110	130
t=3	115	140
Rt	15%	40%
Std	6,45%	21,6%
Rf	4%	4%
Sharpe	1,704%	1,666%

Otros autores, como [25] generalmente aquellos en campos relacionados con la inversión en valor y con metas de inversión amplias en términos temporales, sustentan la idea de que el riesgo debe ser entendido como la pérdida permanente de capital.

Además, dada la irracionalidad de los mercados puede ser común que empresas oscilen ampliamente a pesar de que su valor intrínseco no lo haga con la misma fuerza. Estos movimientos no deberían percibirse como riesgo para el inversor largoplacista. De hecho, este tipo de situaciones puede dar lugar a oportunidades, como las que se pretende encontrar por medio de los modelos. Por ejemplo, observemos el caso de Autozone, empresa líder distribuidora de piezas de automóvil en América. Podemos observar en la Figura 4, la evolución del precio y beneficio por acción. A pesar de mostrar más de 20 años de resultados sólidos, el precio ha variado considerablemente todos los años. Predecir *sharpe-ratios*, *alphas* u otro tipo de medidas de retornos ajustados por riesgo podría hacer perder oportunidades similares, por lo que se considera más adecuado fijar el retorno como variable objetivo de clasificación de los modelos, y posteriormente completar la evaluación de las carteras con medidas de volatilidad.




Figura 4: Evolución Histórica de Precio y Beneficio por acción de AutoZone Inc.

Fuente: TIKR

En su trabajo final de grado [26] titulado “Estrategias de Creación de Carteras de Inversión Basadas en Ciencia de Datos” P. Llobregat aborda el mismo problema haciendo uso también del S&P500 como *benchmark*, también empleando métricas expuestas en este trabajo como fundamentales. Sin embargo, su *dataset* cuenta con histórico limitado evaluando las estrategias únicamente entre 2016 y 2024. Además, solo considera una

selección estática de constituyentes. Para evitar el *look-ahead bias* trabaja solo con empresas activas en el índice antes del 2016. Sin embargo, esto ignora la realidad dinámica del S&P 500, donde la composición de empresas cambia anualmente, afectando significativamente a la viabilidad real de las estrategias.

Adicionalmente [24] establece la variable objetivo en base a rangos fijos de estimación de retorno. Otro aproximamiento interesante podría ser establecer las clases en función de percentiles de retorno para cada ventana, de forma que estas estén balanceadas.

2.10. Propuesta

En el presente trabajo se opta por la reciente definición de riesgo, entendido como pérdida permanente de capital, al trabajar con un *dataset* histórico de inversión superior a 20 años. El objetivo de los algoritmos, por tanto, será el de predecir retornos superiores al S&P500 como *benchmark*, incluso si las carteras desarrolladas en base a los modelos experimentan una mayor volatilidad. Sin embargo, a modo de análisis incluimos la volatilidad de las carteras creadas frente a la volatilidad del índice de referencia como una métrica de evaluación adicional.

Además, a diferencia de estudios previos altamente centrados en predecir movimientos mensuales o incluso semanales, esta propuesta opta por ventanas de predicción anuales, donde los modelos pueden ser más fácilmente interpretables y variables fundamentales aumentan en predictibilidad. En concreto, el objeto de clasificación será el rendimiento desde el punto de vista de mayores retornos de forma consistente con respecto a la media del mercado para cada año.

Los datos son descargados a través de proveedores altamente reconocidos en la industria. Derivados de un análisis de requisitos sobre la selección del proveedor. Los proveedores finalmente escogidos, Nasdaq Data Link y LSEG ofrecen una calidad de datos superior que minimiza la cantidad de valores faltantes o datos anómalos, eliminando la necesidad de incurrir en otras prácticas popularmente empleadas por inversores *retail* como *web-scraping**.

Además, se propone la construcción de un *dataset* dinámico, que refleje la naturaleza del índice S&P500, al incluir información en formato de tipo panel, es decir la combinación de series temporales (últimos 25 años) y datos transversales (500 empresas constituyentes por año).

Mediante la selección del proveedor adecuado, se pretende recuperar información tanto de cotización como de datos fundamentales referentes a las actividades operativas, de financiación y de inversión de las empresas. En el próximo capítulo se explora qué métricas son interesantes y han obtenido cierto éxito, en identificar acciones con retornos extraordinarios. Entre ellas encontraremos algunos factores ya mencionados y otras variables que pueden completar la predictibilidad del modelo.

3. Selección de Variables y Proveedor

3.1. Introducción

En la práctica, los inversores han empleado numerosas estrategias para identificar retornos superiores a la media del mercado. En este capítulo se presentan algunas de las estrategias al alcance del inversor particular y que además cuentan con casos de éxito con retornos auditados. En segundo lugar, se identifican métricas clave sobre las que construir nuestras variables. Algunas de las estrategias coinciden con la revisión de factores previa, mientras que otras son añadidas para intentar mejorar el modelo.

3.2. Value

La inversión en valor o *value investing* parte de la premisa de que el mercado, por razones psicológicas o estructurales, ocasionalmente infravalora empresas en exceso. Benjamin Graham, Warren Buffett o Joel Greenblatt han construido imperios siguiendo estos principios. La evidencia empírica, especialmente la aportada por Fama y French con su factor HML (High Minus Low), demuestra que las acciones con múltiplos bajos (P/E, P/B) tienden a obtener primas de rentabilidad a largo plazo. Estas métricas buscan capturar compañías “baratas” con relación a sus fundamentales, apostando a que el mercado reconocerá ese valor a futuro.

Las principales métricas de valoración se denominan múltiplos o yields:

- Relación entre Precio y Valor en Libros (P/B): $\frac{\text{Precio por acción}}{\text{Valor en Libros}}$ (17)

- Relación entre Precio y beneficio (P/E): $\frac{\text{Precio por acción}}{\text{Beneficios por acción}}$ (18)

- FCF Yield: $\frac{\text{FCF por acción}}{\text{Precio por acción}}$ (19)

- EV/EBITDA: $\frac{\text{Capitalización de Mercado} - \text{Deuda neta}}{\text{EBITDA}}$ (20)

Por ejemplo, en la Figura 5 podemos observar la evolución del índice S&P500 y su valoración en términos de P/E. En los últimos 30 años, el P/E medio del índice ha sido de 16.93 veces. Resulta que los mínimos de cotización suelen coincidir con puntos bajos de valoración, mientras que, en los picos, los participantes están dispuestos a pagar valoraciones más altas por empresas con mismos ingresos, dando lugar inversiones

comparativamente “peores”. En el año 2000 un inversor estaría dispuesto a pagar hasta 25€ por cada euro de beneficio anual mientras que en 2009 únicamente 14€ por cada euro de beneficio anual.




Figura 5: Evolución del S&P500 y su P/E

Fuente: JP Morgan “Guide to the Markets”

Sin embargo, los múltiplos de valoración cuentan con limitaciones a destacar. Por ejemplo, empresas poco intensivas en capital como consultoría, pueden presentar una alta relación entre su precio y sus activos, sin necesariamente indicar sobrevaloración.

De igual modo métricas como el P/E deben contrastarse con empresas comparables en crecimiento o midiendo su variación frente a periodos anteriores, reflejando cambios de atractivo en la valoración.

3.3. Quality

La estrategia *quality* selecciona empresas con ventajas competitivas, balances sólidos y alta rentabilidad sobre el capital. Terry Smith o Thomas Rowe Price han popularizado este enfoque, argumentando que la calidad “compra tiempo” y protege en ciclos adversos. La literatura reciente [20] [21] confirma que la rentabilidad operativa y el bajo apalancamiento son premiados por el mercado. Esto se debe a que empresas de calidad son capaces de subir precios sin perder clientes. Además, su solvencia les habilita adquirir competidores en momentos de dificultades financieras. A largo plazo, estas características permiten compuestos de rentabilidad atractivos, incluso si no parecen baratas en el corto plazo.

La teoría financiera tradicional [27] sostiene que los beneficios de las empresas tienden a estabilizarse y converger hacia la media en el largo plazo (habitualmente representado

por el PIB). Sin embargo, en la práctica existen empresas excepcionales que logran sostener un crecimiento y rentabilidad superior gracias a ventajas competitivas duraderas. Pensemos en Coca Cola o Apple. Dichas marcas están tan integradas en los hábitos del consumidor, que competir contra ellas se hace extremadamente complejo.

Otro hecho indicativo de calidad es la habilidad de la directiva y su capital humano, aunque son datos que de forma general son más costosos de obtener. En concreto, y como se puede observar en la Figura 6, las empresas lideradas por sus fundadores tienden a comportarse mejor que aquellas lideradas por un director externo [28] . Esto puede estar relacionado con la visión y motivación que un fundador aporta en sus decisiones. Algunas métricas que pueden explicar parcialmente esta calidad superior incluyen: el nivel de compensación o el porcentaje de compensación variable (opciones o acciones) sobre el total de compensación.




Figura 6: Outperformance de empresas lideradas por fundadores

Fuente: Bain & Company

En resumen, las métricas más relevantes y mencionadas en la literatura sobre empresas de calidad (factor *quality*) incluyen:

- ROE: $\frac{\text{Beneficios}}{\text{Patrimonio Neto}}$ (21)

- Margen EBIT/operativo: $\frac{\text{EBIT}}{\text{Ventas}}$ (22)

- Presencia o no del fundador

- Participación de la directiva $\frac{\text{Acciones D}}{\text{Total de Acciones}}$ (23)

- Deuda/Equity: $\frac{Deuda}{Patrimonio\ Neto}$ (24)

3.4. Growth

Empresas cuyas ventas, beneficios y otras métricas importantes crecen rápidamente, suelen comportarse mejor en bolsa en periodos largos de tiempo. Cabe matizar que dichas empresas se suelen encontrar a una valoración superior y su compra no siempre está justificada. Sin embargo, popularizada por el renombrado inversor Warren Buffet y otros gestores, la combinación del factor *growth* con los dos factores previos, empresas de calidad y a un precio razonable es una de las temáticas más influyentes en fondos de inversión. En esencia las empresas que crecen suelen experimentar mayor volatilidad dado que su valor está determinado en mayor medida por los flujos de caja más futuros, haciendo que cambios en las tasas de descuento o estimaciones de crecimiento tengan un fuerte impacto en los modelos desarrollados por los analistas. La Ecuación (25) permite derivar la Variabilidad de los beneficios entre el periodo t y $t+1$.

$$\text{Variabilidad de beneficios: } \frac{Beneficios_{t+1}}{Beneficios_t} - 1 \quad (25)$$

Si bien el crecimiento de beneficios es importante, las prácticas contables empleadas por cada constituyente del S&P500 son diversas y atienden a incentivos personales. La Figura 7 muestra la distribución del beneficio neto escalado por capitalización de mercado para empresas con un periodo de listado superior a 20 años. Se observa claramente una concentración anómala justo por encima de cero. Es decir, muchas firmas reportan pequeñas ganancias positivas, y relativamente pocas reportan pequeñas pérdidas, lo que genera el denominado “Kink” en la distribución de beneficios. Este patrón ha sido documentado en múltiples estudios [29] y ha motivado una reflexión crítica sobre la fiabilidad del beneficio contable como métrica de desempeño. Esto conduce a la necesidad de analizar flujos de caja junto con beneficios.




Figura 7: Distribución de Beneficios

Fuente: Burgstahler, D., & Dichev, I. (1997)

Se contrasta el crecimiento en beneficios con el crecimiento en flujo de caja, tal como se establece en la Ecuación (26)

$$\text{Variabilidad de flujos de caja: } \frac{FCF_{t+1}}{FCF_t} - 1 \quad (26)$$

Además, interesa que ambas métricas sean representadas por acción, para reflejar los efectos de dilución que el accionista sufre.

3.5. Momentum

Otra estrategia, defendida por inversores como Richard Driehaus, consiste en comprar lo que ha subido recientemente y vender lo que ha caído, bajo la premisa de que las tendencias suelen persistir. El factor *momentum*, formalizado por Carhart (1997), es una de las anomalías más robustas internacionalmente y se usa ampliamente en *hedge funds* cuantitativos.

Uno de los inversores más aclamados, Stanley Druckenmiller, sostiene que las grandes tendencias en el mercado suelen durar entre 12 y 24 meses, por lo que identificar movimientos fuertes en una etapa temprana y mantener la posición mientras persista el impulso puede generar retornos excepcionales. Su enfoque se basa en detectar cambios macroeconómicos, tecnológicos o de política monetaria que desencadenan ciclos sostenidos, como ocurrió con las acciones tecnológicas entre 2020 y 2021 impulsadas por la digitalización y la expansión monetaria.

Este marco respalda el uso de estrategias de *momentum* basadas en ventanas de retorno de 6 a 12 meses, ya que capturan tendencias que se pueden prolongar durante el año siguiente, justo en el tramo temporal de mayor euforia previo a que la tendencia se revierta o se lateralice. Las Ecuaciones (27) y (28) establecen el cálculo para determinar los retornos de una acción para los últimos 6 y 12 meses respectivamente, considerando $t = 1$ año.

$$\text{Retornos últimos 6 meses: } \frac{\text{Precio}_{t-1/2}}{\text{Precio}_t} \quad (27)$$

$$\text{Retornos últimos 12 meses: } \frac{\text{Precio}_{t-1}}{\text{Precio}_t} \quad (28)$$

3.6. Estrategias técnicas

Otros inversores han empleado reglas técnicas simples como señales de compra/venta, como el cruce de medias móviles o la superación de máximos previos (*breakout*). Estas estrategias buscan aprovechar tendencias o revertir movimientos extremos, asumiendo que los precios reflejan información y psicología colectiva. La estrategia Cruce de medias móviles, establecida en la Ecuación (29), utiliza dos medias móviles (SMA*) de distinta duración para generar señales de compra y venta en función de su interacción. Por ejemplo $SMA(y=1)$ y $SMA(y=2)$. Donde y indica la duración de la media en años. Como se observa en la Figura 8, cuando la SMA corta cruza hacia arriba la SMA larga, se genera una señal alcista (*long*). Cuando la SMA corta cruza hacia abajo la SMA larga, se genera una señal bajista (*short*).

Cruce de SMA*: $SMA\ 1y - SMA\ 2y$ (29)



Figura 8: Crossover de SMA

Fuente: Blog Opofinance (2024)

Si bien se trata de un indicador simple y objetivo, cuenta con ciertas limitaciones. Como retrasos en las señales. Al ser un indicador *lagging*, puede reaccionar tarde ante cambios bruscos de tendencia. Además, puede ocasionar falsas señales en rangos laterales: en mercados sin tendencia clara, puede generar múltiples entradas y salidas sin éxito conocidos como *whipsaws*. Para mitigarlo proponemos usar medias móviles amplias como son 1 y 2 años en ventanas anuales, dado que, al ser más largos, estos SMA's filtran mejor el ruido del corto plazo.

Otros dos indicadores técnicos altamente expandidos son la distancia del precio actual a máximos/mínimos de un periodo. Usado en trading cuantitativo, la diferencia entre el precio actual y el máximo o el mínimo del año muestra que tanta distancia hay entre la cotización actual y la mínima o máxima del año anterior. En estudios como [30] y más

recientemente [31], se observa que las acciones que están cerca de su máximo de 52 semanas tienden a seguir subiendo a corto plazo. Las Ecuaciones (30) y (31) establecen el cálculo de las distancias en entre el precio actual y el máximo y mínimo del último periodo $t-1$ respectivamente.

$$\text{Distancia a máximos: } \frac{\text{Precio MAX}_{t-1}}{\text{Precio}_t} \quad (30)$$

$$\text{Distancia a mínimos: } \frac{\text{Precio MIN}_{t-1}}{\text{Precio}_t} \quad (31)$$

3.7. Esfuerzos inversores

Una métrica común para medir la agresividad con la que las empresas realizan actividades de inversión es el Capex*. En concreto, su magnitud frente a las ventas tal y como se describe en la Ecuación (32) Esta métrica refleja el factor CMA mencionado anteriormente, donde las empresas conservadoras son menos glamurosas, pero en el tiempo tienden a superar a las agresivas en rendimiento, ajustando por riesgo.

$$\text{Gasto en Capex respecto a ventas: } \frac{\text{Capex}}{\text{Ventas}} \quad (32)$$

3.8. Tamaño

Otro factor mencionado previamente era **SMB**. Este argumenta que las empresas de baja capitalización, al partir de una base comparable menor, tienen mayor potencial de crecimiento que las de gran capitalización, ofreciendo en teoría mejores resultados ajustados por riesgo. En este caso, todas las empresas son realmente de gran capitalización al pertenecer al S&P500. Sin embargo, se podría considerar interesante extraer información de la capitalización de mercado para observar si existe diferencia alguna en rendimiento entre las 500 empresas. De hecho, curiosamente, en la última década la concentración del índice ha aumentado drásticamente, haciendo que un selecto grupo de empresas tecnológicas sean las protagonistas. La Figura 9 muestra la evolución en la contribución del top 5 empresas a la capitalización total del índice, resaltando tendencias dinámicas de preferencia de tamaño.



Figura 9: Concentración de Capitalización Bursátil en el Top 5 empresas

Fuente: Blog Opofinance (2024)

3.9. Otros Indicadores

El entorno macroeconómico y la liquidez afectan al atractivo relativo de la renta variable frente a otros tipos de activos, pero también entre empresas más o menos resistentes al ciclo económico. Estrategias exitosas suelen incorporar variables como la tasa libre de riesgo, spreads de crédito o medidas de volatilidad.

- Tasa libre de riesgo (*risk-free rate*)

Se ha tomado como tasa libre de riesgo, el rendimiento a vencimiento (YTM) del bono del Tesoro de Estados Unidos a 10 años, considerado el principal referente mundial por su bajo riesgo de impago. La tasa libre de riesgo es fundamental para valorar inversiones, ya que representa la alternativa de inversión sin riesgo y sirve como mínimo exigible de rentabilidad para los inversores. Cuando esta tasa aumenta, el coste de oportunidad de invertir en acciones también sube, haciendo más difícil justificar inversiones en renta variable y favoreciendo la salida de capital hacia activos seguros. Además, una tasa libre de riesgo elevada suele traducirse en mayores costes de financiación para las empresas, lo que puede afectar negativamente su capacidad de crecimiento e inversión, y en consecuencia influir en la valoración de sus acciones.

- Volumen_{t-1}

El volumen negociado durante el último año ($t-1$) se ha incorporado como métrica relevante porque representa el nivel de liquidez y el interés de los inversores en cada valor. Un mayor volumen suele indicar una mayor facilidad para comprar o vender acciones sin provocar grandes variaciones en el precio, lo que reduce el riesgo de iliquidez para los inversores.

- Volatilidad_{t-1}

La volatilidad del último año ($t-1$) representada como la desviación estándar (σ_{t-1}) al desearse generalmente empresas que experimenten menos variaciones de precio.

3.10. Selección del Proveedor

Como hemos podido observar en el capítulo previo, una gran cantidad de variables proviene de información referente a las actividades operativas, de inversión y financiación de la empresa. Esta información se hace pública mediante la publicación de los estados financieros de forma trimestral y anual. Además, la información referente a la cotización y volumen de acciones negociado es conocida públicamente, pero recolectada por entidades como la bolsa de Nueva York (NYSE). En este capítulo se justifica la selección del proveedor empleado en la extracción de datos, que cuente con las variables, factores y métricas deseados.

En Estados Unidos el organismo encargado de regular la correcta y efectiva publicación de resultados de empresas cotizadas es la SEC (*Securities and Exchange Commission*). Esta información es accesible mediante su buscador EDGAR. Sin embargo, el entrenamiento de modelos requiere de datos estructurados comúnmente en formato de datos tabulados. Como se mencionó en la propuesta tras la revisión de la literatura, una posible solución sería realizar *web-scraping*, si bien esto aumenta el nivel de detalle y personalización sobre la información escogida, complicaría exponencialmente nuestro objetivo final y materia de este trabajo, la elaboración de modelos. Otra posible alternativa es el uso de proveedores que ofrecen directamente datos sobre estados financieros. Un proveedor común, es Nasdaq-Data-Link (NDL) conocido previamente como Quandl. A través de su plataforma, NDL comercializa bases de datos de terceros como Sharadar, una firma independiente fundada en 2013 especializada en extracción, estandarización y agrupación de información financiera en base a presentaciones de empresa. Una de las publicaciones mencionados previamente [24] emplea precisamente este proveedor.

En concreto NDL cuenta con un producto denominado “Sharadar Core US Equities Bundle” con un historial desde 1998 hasta 2025, cubriendo más de 16.000 empresas en

Estados Unidos. El producto tiene un coste de \$69/mes y consiste a su vez en la agrupación de 5 sub-productos:

- Core US Fundamentals data
- Core US Insiders data (solo disponible desde 2008)
- Core US Institutional Investors
- Sharadar Equity Prices.
- Sharadar Fund Prices

El presente trabajo se centra en Core US Fundamentals Data para la obtención de datos fundamentales y Equity Prices para el cálculo de indicadores técnicos, rendimiento, volumen y *momentum*. Desgraciadamente Core US Insiders cuenta solo con datos desde 2008. En este trabajo se ha preferido aprovechar un amplio *dataset* (1998-2025) a incluir el factor Insider, por lo que este se deja para futuras ampliaciones o mejoras. El resto de productos no son relevantes para el trabajo.

Core US Fundamentals Data:

Se compone de 7 tablas que agrupan información en función de su carácter. La más importante es SF1 que cuenta con 150 indicadores fundamentales. Además, otra tabla denominada S&P500, provee información sobre las empresas activas, y deslistadas en el índice, permitiendo así la reconstrucción de un *dataset* con empresas solo activas en el índice en cada momento.

Equity Prices

Cuenta con una tabla SEP con datos diarios de precio EOD*, esto resulta interesante ya que si bien trabajaremos con ventanas anuales, la granularidad diaria permite capturar patrones temporales más finos, abriendo la puerta a métricas más sofisticadas para alimentar el modelo de predicción, como la volatilidad anualizada, momentum o el *drawdown* máximo.

Además, Equity prices ofrece precios ajustados por *splits*, *spin-offs* y dividendos. Esto es esencial para el análisis de desempeño relativo entre acciones, ya que elimina distorsiones causadas por eventos corporativos. Por ejemplo, una acción que experimenta un *split* puede parecer haber perdido valor si no se ajusta correctamente el precio. De igual forma, los dividendos reducen el precio de mercado, pero no representan una pérdida real para el inversor

LSEG Data Platform

Adicionalmente, durante la elaboración de este trabajo, el alumno realizó una estancia en un programa de intercambio, y se interesó por una base de datos denominada LSEG Data Analytics, ofrecida a través de la universidad de destino. LSEG es junto a Bloomberg la plataforma líder usada por profesionales de la inversión cuantitativa. Sin embargo, el acceso ofrecido limitaba la posibilidad de extracción a consultas de tipo REST ligeras, con un servicio a parte para descargas de tipo *bulk*, por lo que su aplicación

a la descarga de grandes cantidades de datos se veía limitada. Es por ello que se decidió hacer un uso marginal de esta, completando los indicadores de NDL con datos macroeconómicos comunes a todas las empresas para cada año como es la tasa libre de riesgo.



Figura 10: Proveedores empleados

Fuente: nasdaq.com, lseg.com

3.11. Conclusiones

En este capítulo se han explorado diversas estrategias de inversión reconocidas tanto en la literatura académica como en la práctica profesional, desde enfoques fundamentales como *Value*, *Quality* y *Growth*, hasta estrategias técnicas, basadas en *momentum* o contexto macroeconómico. Si bien ninguna estrategia es universalmente superior ni garantiza resultados consistentes en todo momento, cada una aporta una perspectiva valiosa sobre los factores que pueden influir en el desempeño futuro de una acción.

El análisis conjunto de estas estrategias permite construir un conjunto de variables amplio y complementario. Al incorporar métricas relacionadas con valoración, rentabilidad, crecimiento, tendencia de precios, tamaño, inversión de capital y entorno financiero, se busca ofrecer al modelo un marco rico en información que refleje tanto la situación interna de la empresa como las condiciones externas del mercado.

El objetivo no es replicar ciegamente ninguna estrategia en particular, sino entrenar un modelo capaz de identificar patrones comunes entre empresas exitosas. Se espera que este modelo aprenda a reconocer combinaciones favorables de múltiples métricas, incluso si cada una por separado tiene limitaciones, y que, al hacerlo, aumente la probabilidad de detectar empresas con alto potencial de generar retornos extraordinarios. Adicionalmente se han seleccionado proveedores adecuados y reconocidos ampliamente como son Nasdaq Data Link y LSEG. Estos ofrecen precisamente aquellos datos necesarios para construir el *dataset* sobre el que entrenar los modelos, con guías prácticas y documentación de calidad.

En definitiva, este enfoque multifactorial ofrece una base sólida para el desarrollo de modelos predictivos que integren tanto la teoría financiera como la evidencia empírica en un marco cuantitativo de toma de decisiones.

4. Análisis del Problema

4.1. Introducción

Hasta ahora se ha propuesto el contexto y revisión de la literatura referente a la identificación de acciones con rendimientos superiores al mercado. Se ha seleccionado una serie de variables para la construcción de modelos de clasificación y escogido un proveedor capaz de satisfacer las necesidades de información. En este capítulo se provee una definición formal del problema, pretendiendo comprender la magnitud del problema, los requisitos del diseño experimental, el marco legal relacionado con la construcción y comercialización de modelos y finalmente riesgo y grados de libertad que no se fijan, sino se exploran durante la experimentación.

4.2. Definición formal del Problema

El problema consiste en la aplicación de algoritmos, capaces de clasificar correctamente acciones según su rendimiento a un año. Esto permitirá la construcción de una cartera con rendimientos superiores a los del mercado. Dicha cartera es construida mediante la selección de ' n ' constituyentes del S&P500, a principio de cada ventana anual con una alta probabilidad de obtener rendimientos superiores al mercado.

Para ello primero debemos definir qué rendimientos son superiores a nuestro *benchmark*, el S&P500. En la Sección 1.1 Contexto, se comentó que el rendimiento del S&P500 desde 1928 a 2024 fue del 6,7%. Al añadir la rentabilidad por dividendos, el rendimiento se incrementa a 9,6%. Rendimientos por encima de esa cifra son considerados superiores al mercado y serán de forma general el objeto de identificación. Adicionalmente es importante establecer las clases de forma balanceada, surgiendo dos posibilidades consideradas en la literatura: Clases definidas por rangos continuos [24] o clases definidas por percentiles [22].

Como se mencionó anteriormente se trabaja con múltiples empresas (500) en diversos años, lo que hace de este problema, una tarea con datos panel o longitudinales. Esto supone retos en la construcción del *dataset* así como el esquema de validación escogido. En las próximas secciones de este capítulo expandimos los requisitos del diseño y las adversidades del experimento.

4.3. Requisitos Funcionales y no Funcionales

4.3.1. Requisitos Funcionales

El sistema propuesto debe ser capaz de realizar las siguientes funciones para permitir el desarrollo y evaluación de estrategias de inversión basadas en aprendizaje automático:

- **Ingestión y preprocesamiento de datos:** Importar datos históricos de precios y fundamentales de activos financieros, gestionar valores faltantes, y asegurar la calidad de los datos.
- **Ingeniería de características:** Calcular métricas relevantes como medias móviles, volatilidades históricas, ratios financieros y otros indicadores técnicos y fundamentales.
- **Entrenamiento de modelos predictivos:** Implementar y entrenar modelos de regresión y clasificación, tales como *Ridge Regression*, *Random Forest* y *XGBoost* y *DNN's* para predecir retornos o categorías de rentabilidad futura.
- **Validación temporal:** Emplear técnicas de validación específicas para series temporales, como el esquema *walk-forward*, con el fin de evitar el uso indebido de datos futuros.
- **Evaluación de modelos:** Generar métricas de desempeño mencionadas en el Estado del Arte.
- **Selección de activos:** Construir carteras de inversión seleccionando los n activos con mejores predicciones de rentabilidad, según un umbral definido.
- **Visualización de resultados:** Producir gráficos de rendimiento acumulado, evolución de las métricas a lo largo del tiempo, y visualizaciones de clasificación como matrices de confusión y gráficos de dispersión Predicho vs Actual.

4.3.2. Requisitos No Funcionales

Además de las funcionalidades descritas, el sistema debe cumplir con los siguientes requisitos de calidad:

- **Eficiencia computacional:** Los tiempos de entrenamiento y evaluación deben ser razonables para *datasets* medianos, permitiendo iteraciones rápidas y exploración de diferentes configuraciones.

- **Integridad de los datos:** Debe garantizarse la consistencia y corrección de los datos durante todo el proceso, detectando y tratando adecuadamente valores extremos, inconsistencias y datos faltantes.
- **Modularidad:** El sistema debe estar estructurado de forma modular para facilitar la reutilización y la extensión de componentes individuales, como los módulos de ingestión de datos, preprocesamiento, modelado y evaluación.
- **Escalabilidad:** El sistema debe ser capaz de adaptarse a un incremento en la cantidad de activos analizados, en el número de años de datos históricos o en el número de características utilizadas.
- **Reproducibilidad:** Se debe garantizar que, bajo condiciones idénticas de datos y parámetros, los resultados obtenidos sean reproducibles mediante la fijación de semillas aleatorias y el control del entorno de ejecución.
- **Robustez frente a errores:** El sistema debe ser capaz de manejar errores inesperados, como fallos de lectura de datos o cálculos numéricos, proporcionando mensajes claros y mecanismos de recuperación cuando sea posible.

4.4. Análisis del Marco Legal y Ético

El desarrollo de estrategias de inversión basadas en técnicas de aprendizaje automático involucra consideraciones legales y éticas que deben ser tenidas en cuenta para garantizar el cumplimiento normativo y la responsabilidad profesional.

4.4.1. Marco Legal

- **Protección de Datos:** Los datos utilizados en este proyecto son de naturaleza financiera, públicos y no contienen información personal identificable (PII). En algoritmos que operen con otro tipo de datos, es esencial asegurar que el tratamiento de los datos cumpla con los principios de protección de datos y privacidad establecidos, por ejemplo, por el Reglamento General de Protección de Datos (GDPR) en Europa. Además, los servicios contratados mediante NDL y LSEG permiten la construcción y desarrollo de herramientas en base a los datos que ofrecen, pero no la reventa de datos a terceros.
- **Regulación Financiera:** En el ámbito financiero, los algoritmos que impactan decisiones de inversión pueden estar sujetos a regulación bajo directivas como 2014/65/EU - MiFID II (*Markets in Financial Instruments Directive*) en la Unión Europea. Únicamente entidades autorizadas por la

CNMV* en España pueden ofrecer recomendaciones de inversión. Aunque este proyecto se realiza con fines académicos y no implica recomendaciones reales de inversión, es importante considerar que, en un entorno profesional, las estrategias basadas en aprendizaje automático deben ser auditables, explicables y cumplir con los requisitos regulatorios de transparencia y gestión de riesgos.

4.4.2. Marco Ético

Además de los aspectos legales, el uso de machine learning en estrategias de inversión plantea importantes cuestiones éticas:

- **Transparencia y Explicabilidad:** Es fundamental que los modelos empleados sean interpretables hasta cierto nivel, para evitar decisiones de tipo caja negra o *black-box*. La trazabilidad de las decisiones de inversión es especialmente relevante en el cumplimiento de MiFID II, que exige que los clientes puedan comprender los riesgos de las recomendaciones recibidas.
- **Evitar Overfitting y Optimización Excesiva:** Éticamente, se debe evitar la construcción de modelos sobreajustados a datos históricos, conocido como *data snooping bias* que puedan presentar expectativas de rentabilidad no realistas.
- **Responsabilidad sobre Decisiones Automatizadas:** En caso de implementación real, sería necesario establecer claramente la responsabilidad en las decisiones tomadas por sistemas automáticos, conforme a las normativas de protección al inversor.

4.5. Análisis de Riesgos

Los principales riesgos en la construcción de modelos implementados en decisiones de inversión incluyen:

4.5.1. Máximo Drawdown

En el presente trabajo se proponen estrategias de inversión basadas en acciones sin apalancamiento, es decir, sin recurrir a financiación externa o endeudamiento. Este enfoque implica que el inversor no puede perder más que el capital inicialmente aportado. En consecuencia, la pérdida máxima posible en el peor de los escenarios sería la pérdida total del capital invertido.

4.5.2. Look-ahead bias

El *look-ahead bias* ocurre cuando el modelo utiliza información que no estaría disponible en el momento real de la predicción. Esto genera una visión artificialmente optimista del desempeño futuro, ya que el modelo, inadvertidamente, aprende de datos futuros.

Para mitigar este riesgo es crucial respetar el orden temporal en el entrenamiento y validación, así como emplear técnicas de validación específicas para datos en formato panel. Adicionalmente, como se observa en la Figura 11, se debe utilizar constituyentes dinámicos de los índices de mercado, es decir, listas de activos que reflejan la composición vigente en cada momento histórico, evitando usar información de constituyentes futuros no conocidos en ese instante.




Figura 11: Constituyentes dinámicos

Por último, se debe asegurar ventanas de entrenamiento que solo contienen información pasada hasta el momento de cada predicción. Por ejemplo, con los datos fundamentales, se asegura que únicamente se utilicen estados financieros publicados antes de la fecha de referencia. No se utilizan cifras revisadas o *re-statements* posteriores que serían desconocidos en tiempo real.

4.5.3. Overfitting

El *overfitting* ocurre cuando el modelo se ajusta excesivamente a los datos de entrenamiento, capturando ruido en lugar de patrones generalizables. Esto es especialmente crítico en mercados financieros, donde la relación señal-ruido es baja y

los patrones históricos pueden no repetirse en el futuro. Mediante un *backtest* se pretende validar las estrategias sobre datos no observados por el modelo.

Medidas adoptadas para mitigar el riesgo de *overfitting*:

- Regularización: Se emplean técnicas como la penalización L2 en Ridge Regression o la regularización incorporada en XGBoost (L1/L2).
- Separación de conjuntos de datos: El conjunto de datos se divide en tres bloques:
 - *Train set*: Para entrenar el modelo.
 - *Validation set*: Para ajustar los hiperparámetros mediante técnicas de búsqueda como *grid search* o *random search*.
 - *Test set*: Reservado exclusivamente para la evaluación final, asegurando que los resultados son verdaderamente fuera de muestra.
- Control de la complejidad del modelo: Se limitan parámetros como la profundidad máxima de los árboles o el número de estimadores en métodos ensemble para evitar modelos demasiado flexibles.
- Evaluación de desempeño en datos no vistos: Se reportan métricas de desempeño (matriz de confusión) utilizando exclusivamente el Test set para garantizar la validez de los resultados.

4.6. Identificación de Posibles Experimentos

El desarrollo de carteras basadas modelos de ML presenta múltiples grados de libertad que deben ser definidos cuidadosamente. Estas decisiones abarcan desde la elección del modelo y la forma de validar, hasta cómo se preprocesan los datos o se definen las clases objetivo. A continuación, se describen los principales aspectos analizados:

1. Modelos de clasificación

Existen numerosos enfoques para abordar un problema de clasificación multiclase en datos financieros en panel. Entre los modelos más frecuentes en la literatura se encuentran:

- Modelos lineales como regresión logística o *Linear Discriminant Analysis* (LDA).
- Árboles de decisión y métodos ensemble como Random Forest y XGBoost.
- Modelos más recientes como redes neuronales profundas (DNNs) y otros basados en aprendizaje profundo.
- LightGBM, *Support Vector Machines* (SVM).

Cada uno ofrece distintos compromisos entre interpretabilidad, capacidad de modelado no lineal y rendimiento computacional.

2. Estrategia de validación

Al trabajar con datos temporales, se debe respetar la estructura cronológica para evitar *data leakage* (introducir datos futuros al modelo). Algunas estrategias son

- División aleatoria: desestimada por romper la estructura temporal.
- Validación tipo *k-fold* adaptada temporalmente: útil para algunos estudios, pero compleja de implementar de forma estable.
- Validación por ventana deslizante (*walk-forward*): seleccionada por su coherencia con el uso real del modelo. Se entrena con los últimos n años y se evalúa sobre el siguiente.

3. Definición de las clases objetivo

Una decisión fundamental es cómo transformar un retorno continuo en una clase discreta. Dos aproximaciones evaluadas son:

- Clasificación por quintiles o percentiles, como se hace habitualmente en finanzas cuantitativas.
- Clasificación por rangos de retorno absolutos, como se ve en estudios centrados en interpretabilidad financiera (ej. retorno $\geq 15\%$ = clase 4).

4. Horizonte temporal de entrenamiento y datos

Se pueden considerar diferentes longitudes para la ventana de entrenamiento, validación y test. De forma general se suele usar un 80% de datos en el entrenamiento y 20% en el Test, siendo el segmento de validación de hiperparámetros una parte del entrenamiento. Una ventana más larga puede incluir más datos, pero perder relevancia, mientras que una más corta puede capturar mejor el comportamiento reciente. Además, la selección de diferentes periodos históricos puede resultar en modelos diversos. Es recomendable incluir al menos 1 o 2 años de recesión en los mercados.

5. Tratamiento de valores faltantes

Se consideran varias alternativas de tratamiento de registros con valores nulos:

- Imputación con medias.
- Eliminación de columnas o filas
- *Forward fill*, que se utilizó por su coherencia con datos financieros y por no introducir información futura.

6. Restricciones de cartera

El tamaño de la cartera seleccionada afecta directamente a la diversificación. Según la teoría de portafolios existen múltiples restricciones impuestas por inversores: como liquidez, apalancamiento, distribución de pesos, carteras *long-only* o *long-short* que incluyen posiciones bajistas.

4.7. Solución Propuesta y Arquitectura

La solución propuesta consiste en construir un marco comparativo de modelos de clasificación supervisada para predecir el rendimiento futuro relativo de activos financieros y generar carteras a partir de las predicciones.

Modelos seleccionados para comparación:

1. **Modelo base:** regresión logística multiclase, útil como línea base interpretable.
2. **XGBoost:** modelo potente y bien establecido para datos estructurados, capaz de modelar relaciones complejas sin requerir normalización.
3. **Red neuronal profunda (DNN):** modelo con alta capacidad expresiva, adecuado para problemas no lineales y tareas de ranking.

Estos tres modelos representan diferentes niveles de complejidad y aproximaciones metodológicas. Todos se entrenan con la misma estructura de validación temporal y conjunto de datos, lo que permite una comparación justa y controlada.

Se ha optado por el mayor conjunto de datos disponibles por el proveedor Nasdaq Data Link, que ofrece datos fundamentales y de precio desde 1998 hasta 2025. Como se ha mencionado ya, se opta por ventanas anuales donde datos financieros pueden tener más predictibilidad sobre retornos según las estrategias comentadas.

El enfoque de experimentación sigue las siguientes fases:

1. **Recolección y consolidación de datos:** recuperación de todas las variables contables, de precios y metadatos necesarios para construir las métricas.
2. **Reconstrucción de universo de activos:** generación de la lista de constituyentes del S&P 500 para cada año del análisis.
3. **Tratamiento de valores faltantes:** imputación mediante forward-fill y eliminación controlada según la disponibilidad.
4. **Ingeniería de características:** cálculo de métricas financieras estandarizadas (factores de valoración, calidad, momentum, etc.).
5. **Definición de variable objetivo:** construcción de clases multiclase basadas en rangos fijos de retorno a 12 meses, con cinco categorías ordinales de rendimiento.
6. **Normalización de datos:** escalado de las variables con StandardScaler, ajustado exclusivamente sobre el conjunto de entrenamiento de cada año.

7. **Entrenamiento de modelos:** implementación del modelo base, XGBoost y DNN bajo el esquema de validación por ventana deslizante.
8. **Evaluación comparativa:** análisis de métricas de clasificación (*accuracy*, *precision*, *recall*) y métricas financieras

Este enfoque permite analizar empíricamente cuál de los modelos produce mejores resultados financieros, evaluando no solo la capacidad de clasificación, sino también su utilidad práctica al construir carteras. La solución se enmarca así no solo como un desarrollo técnico, sino como una contribución metodológica al uso de ML en *asset allocation*.

Como se establece en la Sección 1.5 Metodología, en el presente trabajo se opta por un *pipeline* clásico de ML. Mediante éste, el objetivo es transformar una serie de datos brutos (aunque incluyen cierto preprocesado ya) en conocimientos accionables, en la forma de modelos de decisión. La naturaleza modular del *pipeline* permite el desarrollo por etapas, las cuales pueden ser iterativas sin necesidad de rehacer todo el progreso. Gracias a esta arquitectura cualquier resultado es reproducible y su división facilita la trazabilidad. Dado que se busca obtener modelos lo más robustos posibles, se ha incurrido en numerosas iteraciones de las etapas presentadas a continuación en la Figura 12. Algunos de estos ajustes menos relevantes se han dejado fuera de la extensión de la memoria con el propósito de ofrecer un seguimiento comprensivo al lector.




Figura 12: Arquitectura del Pipeline de Datos y Modelado

4.8. Plan de Trabajo

El desarrollo del presente TFG se ha estructurado en las siguientes fases principales, inspiradas en la metodología de proyectos software y adaptadas a la naturaleza multidisciplinar de este trabajo.

4.8.1. Estimación de Esfuerzos:

Fase	Descripción breve	Horas estimadas	Horas reales
1. Revisión bibliográfica y definición	Investigación de estrategias, revisión de literatura y planteamiento del problema.	40 h	50 h
2. Obtención y procesamiento de datos	Búsqueda, contratación y extracción de fuentes de datos; limpieza y preprocesado.	60 h	100 h
3. Ingeniería de características	Selección, transformación y generación de variables predictoras.	50 h	60 h
4. Diseño y entrenamiento de modelos ML	Implementación de modelos, ajuste de hiperparámetros y validación.	80 h	60 h
5. Backtesting y análisis de resultados	Simulación de carteras, análisis comparativo y visualización.	70 h	60 h
6. Documentación, memoria y conclusiones	Redacción de memoria, elaboración de anexos y materiales gráficos.	80 h	60 h
7. Reuniones de seguimiento y tutorías	Coordinación con tutores, revisión de avances y correcciones.	10 h	10 h
Total		350 h	400 h

Nota: Las horas reales se han ido ajustando conforme el avance del desarrollo, redistribuyendo el esfuerzo en función de los retos encontrados en cada fase.

4.8.2. Presupuesto

En base a nuestras estimaciones de esfuerzos iniciales, el desarrollo completo del software habría requerido un total aproximado de 350 horas realizadas por un estudiante de doble grado en Ingeniería Informática y ADE aún no titulado. El salario bruto de un recién titulado en este perfil suele situarse en torno a 21.000 €/año, lo que implica un coste empresa de 27.468 € anuales (según estimaciones estándar), es decir, 13,20 €/hora (calculado sobre 2.080 h/año).

Considerando un descuento del 30% por tratarse de un alumno no titulado:

- Coste hora estimado alumno: $13,20 \text{ €} \times 0,7 = 9,24 \text{ €/h}$
- Coste total de desarrollo: $350 \text{ h} \times 9,24 \text{ €} = 3.234 \text{ €}$

A ello hay que sumar los siguientes costes asociados:

- Acceso a base de datos US Core Bundle: $60 \text{ €/mes} \times 3 \text{ meses} = 180 \text{ €}$
- Acceso a base de datos LSEG Data Platform: $2000 \text{ €/mes} \times 2 \text{ meses} = 4000 \text{ €}$
- Asesoramiento senior/tutorías: $2 \text{ tutores} \times 10 \text{ h} \times 38,65 \text{ €/h} = 773 \text{ €}$

Total presupuesto estimado: 8.127 €

4.9. Tecnologías y Herramientas

4.9.1. Entorno de desarrollo

- **Lenguaje:** Se utilizó Python por ser el lenguaje dominante en ciencia de datos, con amplias librerías para machine learning y análisis financiero.
- **IDE:** El entorno de trabajo **fue Visual Studio Code** con la extensión oficial de Jupyter. Esta integración permite:
 - Ejecutar y depurar notebooks directamente.
 - Versionar cambios en el código.
 - Alternar entre desarrollo exploratorio e implementación modular.
- **Estructura modular:** Se organizó el proyecto en carpetas funcionales (/data, /models, /notebooks, /config) para mantener una arquitectura reproducible.
- **Entorno virtual:** La creación de un entorno virtual aislado con requirements.txt permitió el control total de versiones de paquetes.

4.9.2. Herramientas complementarias

- **Git y GitHub:** Se utilizó control de versiones para registrar el progreso, asegurar la trazabilidad y permitir la monitorización entre tutor y alumno
- **Obsidian:** Herramienta empleada para anotar ideas, estructurar el marco teórico y recolectar referencias durante el proceso de investigación.
- **Canvas:** Utilizado para el diseño de diagramas de flujo y esquemas visuales como el pipeline del sistema (i.e: ver Figura 12).

4.9.3. Principales Librerías

- **pandas, numpy:** Manipulación eficiente de datos financieros estructurados.
- **scikit-learn:** Implementación de modelos básicos, validación temporal y métricas.
- **xgboost:** Entrenamiento del modelo XGBoost, con capacidad de ajuste de hiperparámetros y manejo eficiente de datos tabulares.
- **keras / tensorflow:** Definición, entrenamiento y evaluación de redes neuronales profundas (DNN).
- **nasdaqdatalink y lseg.data:** Librerías específicas para interactuar con las APIs de Nasdaq Data Link y LSEG, facilitando la descarga de datos históricos fundamentales, de precio y macroeconómicos.
- **ta (Technical Analysis Library):** Generación de indicadores técnicos de análisis bursátil.
- **matplotlib, seaborn, missingno:** Visualización de datos, gráficos financieros y análisis de valores faltantes.
- **tqdm:** Progreso de loops largos, especialmente útil durante búsquedas de hiperparámetros.

4.10. Conclusiones

El Capítulo 4 Análisis del problema, ha establecido los fundamentos técnicos, legales y operativos necesarios para abordar el diseño de modelos de clasificación supervisados aplicados a la predicción de rendimientos bursátiles. Se ha definido formalmente el problema, identificado los requisitos funcionales y no funcionales del sistema, y detallado tanto el marco legal como los principios éticos que condicionan el desarrollo responsable de herramientas de inversión automatizadas. Asimismo, se han analizado los principales riesgos inherentes al uso de ML en este contexto, como el look-ahead bias o el *overfitting*, junto con medidas concretas para su mitigación que serán aplicadas en el entrenamiento, validación y evaluación de los modelos. El capítulo también destaca los grados de libertad presentes en el diseño experimental, como la estrategia de validación o la definición de clases objetivo y propone un enfoque metodológico reproducible basado en un pipeline modular. Finalmente, se ha proporcionado una estimación detallada del esfuerzo necesario y del coste económico para replicar el proyecto, así como una relación de herramientas y tecnologías empleadas, lo que aporta una base sólida y realista para la implementación práctica del sistema propuesto.

5. Creación del dataset

5.1. Introducción

Tras realizar toda la introducción necesaria, definir variables, problema y estructura experimental, se procede a los pasos necesarios para la creación de un *dataset* base. Este es un conjunto de datos final que es usado como punto de partida para entrenar los modelos. A lo largo del capítulo se establecen varias decisiones clave durante la construcción del *dataset*. Si bien no se entra en detalle en todas las alternativas o errores cometidos, se ofrece la versión de experimentación final más robusta.

5.2. Ingestión de datos

El proceso de construcción del *dataset* comienza con la ingestión automatizada de datos mediante APIs del proveedor financiero Nasdaq Data Link (anteriormente Quandl). Se utiliza el producto US Core Equity Bundle, que proporciona acceso en tiempo real o con retraso a variables fundamentales, de precios y de mercado para más de 16.000 empresas en Estados Unidos.

Entre las tablas accesibles de este producto, se emplea la API de tablas ("*Tables API*") de Nasdaq Data Link, la cual permite acceder a conjuntos de datos históricos de alta calidad organizados en formato tabular. Esta API no proporciona datos en tiempo real, sino actualizaciones diarias con un desfase de un día, lo que resulta perfectamente adecuado para análisis con enfoque histórico como el de este trabajo.

Tras la creación de una cuenta y credenciales, se hace uso de las API *keys* proporcionadas por ambos proveedores. Estas son configuradas en formato `.json` en un directorio `/config` desde donde se puedan referenciar. Así el proyecto evita filtrar esta información sensible al incluir la carpeta en el conjunto de archivos que git debe ignorar (`.gitignore`)

```
with open(r'..\config\ndl-config.json') as f:
    config = json.load(f)

api_key = config['API_KEY']
ndl.ApiConfig.api_key = api_key
```

La extracción de datos se lleva a cabo para 4 tablas.

- Datos fundamentales (SF1)
- Datos de Cotización (SEP)
- Constituyentes históricos (S&P500)
- Tasa libre de Riesgo

A continuación, se observa la extracción de los constituyentes históricos del S&P500, donde se toma datos únicamente para el mes 3 (marzo) de cada año.

```
all = ndl.get_table("SHARADAR/SP500", action = "historical",
date={'gte':start_date}, paginate=True)

sp500 = all[all['date'].dt.month == 3]
sp500.drop(columns=['action', 'name', 'contraticker',
'contraname','note'], inplace=True)
```

La selección de marzo como ventana no es arbitraria. Dado que la mayoría de las empresas tienen años fiscales que coinciden con el año natural, acaban presentando resultados durante el primer trimestre (Q1) del año siguiente ($t+1$). Al extraer datos de marzo obtenemos las 500 empresas que constituían el índice S&P500 el 31/3 de cada año.

De igual modo, se extraen los datos fundamentales de la tabla SHARADAR/SF1, que contiene información fundamental de las empresas. Se realiza la extracción para los 1132 *tickers* únicos guardados en “tickers”, que representan los constituyentes históricos del S&P500 en nuestro universo temporal (1998-2025). En la Tabla 2 se exponen las métricas extraídas de NDL, las cuales serán transformadas en variables más refinadas definidas en el Capítulo previo 4. Selección de Variables y Proveedor. Dichas métricas extraídas son definidas en una lista “fundamental_col”.

```
fundamental = ndl.get_table(
    "SHARADAR/SF1",
    ticker=tickers,
    calendarDate={"gte": start_date},
    dimension="ARY",
    qopts={"columns": fundamental_col},
    paginate=True
)
fundamental = fundamental.rename(columns={"calendardate":"date"})
fundamental["date"] = pd.to_datetime(fundamental["date"])
fundamental["year"] = fundamental["date"].dt.to_period("Y")

fundamental.to_csv(r'data\fundamental.csv')
```

Columnas a extraer de SF1 (fundamental_col):

Tabla 2: Columnas extraídas de SF1

ticker	ID de la empresa
datekey	Fecha de Publicación de Resultados
calendardate	Fecha de Año Fiscal (FY)
revenue	ventas
eps	Beneficio por acción
ebitda	Beneficios antes de intereses, impuestos, depreciación y amortización
netinc	Beneficio neto
roe	Retorno sobre patrimonio neto
evebitda	Valor de empresa/ EBITDA
fcfps	Flujo de Caja por acción
pb	Precio / Valor en Libros
marketcap	Capitalización Bursátil de Mercado
ebit	Beneficios antes de intereses e impuestos
currentratio	Activos corrientes / pasivos corrientes
capex	Gastos de Capital
ncfo	Flujo de caja operativo neto
de	Deuda / Patrimonio Neto

Igualmente, se realiza la descarga de precios desde la tabla SHARADAR/SEP. Dado que se necesita extraer métricas de precio como el máximo, mínimo o retorno en los últimos 6 meses, la granularidad de esta tabla es diaria. Con un volumen de 1132 constituyentes históricos durante 27 años (1998-2025) y precios diarios, la tabla es pesada (7M de fila) y requiere ser extraída en formato .zip.

Antes de cruzar los datos con la tabla de constituyentes del índice (S&P 500), se realiza un procesamiento específico sobre los precios históricos y sobre las métricas fundamentales de todas las empresas. Esta decisión metodológica es crítica, ya que el *merge* con constituyentes elimina los registros de empresas que aún no forman parte del índice en una fecha dada, aunque ya dispongan de datos históricos que podrían contener información predictiva valiosa.

1. Variables Técnicas

Como primer paso, se selecciona el último día hábil de marzo de cada año como fecha de rebalanceo. Esta referencia permite capturar un año completo de información reciente antes de la formación de carteras. A partir de ahí, se generan variables para cada combinación de empresa y año mediante ventanas retrospectivas de 1 y 2 años:

- Precio ajustado de cierre a fecha de rebalanceo (`close_reb_adj`)
- Promedios móviles de precios desde hace 1 y 2 años (`sma_1y`, `sma_2y`)
- Máximos y mínimos anuales (`max_1y`, `min_1y`)
- Volumen negociado en el último año (`vol_1y`)
- Volatilidad anualizada basada en retornos diarios (`volatility_1y`)

Estas variables técnicas permiten capturar el comportamiento reciente del activo, tanto en precio como en volumen y riesgo.

2. Variables Fundamentales

Del mismo modo, las métricas fundamentales (ingresos, beneficios, flujos de caja, ratios de valoración, etc.) también se procesan previamente. Se calcula el crecimiento interanual (*year-over-year*) para diversas variables clave, cuya capacidad predictiva radica más en su variabilidad año sobre año que en su valor per-se.

```
# 2. Calcular el crecimiento YoY (% Change respecto al año anterior) para
variables fundamentales
for col in ['revenue', 'ebitda', 'ebit', 'eps', 'equity', 'capex', 'pe',
'pb', 'fcfps', 'ncfo']:
    fundamental[f'{col}_yoy'] =
fundamental.groupby('ticker')[col].pct_change()
```

La razón para realizar ambos procesos antes de unir los datos con la tabla de constituyentes se basa en evitar el sesgo de supervivencia: muchas empresas muestran señales informativas incluso antes de formar parte del índice. Si las transformaciones se hicieran después del *merge*, se perdería todo rastro de aquellas empresas en sus años previos a entrar en el índice, limitando así la potencia predictiva del modelo. Este enfoque garantiza una cobertura temporal completa y una visión más realista del universo invertible, tal como lo vería un inversor en cada punto del tiempo.

5.3. Unificación

Una vez generadas las cuatro tablas principales y guardadas de forma persistente en formato .csv, se procede a su unificación mediante uniones temporales controladas. Para ello, se utiliza la función `pd.merge_asof` de la librería pandas, que permite fusionar las tablas asegurando que solo se utilicen datos disponibles antes del momento de inversión, evitando así cualquier riesgo de *look-ahead bias*.

El conjunto de datos se construye partiendo de un *snapshot* anual de los constituyentes del S&P500, tomado alrededor del 31 de marzo de cada año, fecha que marca el punto de toma de decisiones. A partir de este punto de referencia, se integran:

- **Variables técnicas**, calculadas exclusivamente con precios observados antes del *snapshot*.
- **Datos fundamentales**, vinculados solo si ya se habían publicado antes de esa fecha (según la columna `report_date` del informe financiero).

Ambas integraciones se realizan de forma retrospectiva, garantizando que cada observación solo incorpora información que un inversor real podría haber consultado en ese momento (*ex ante*). En los casos en que los datos fundamentales no estén disponibles dentro de la ventana de rebalanceo, la empresa se considerará en la siguiente ventana anual.

Tras esta serie de pasos obtenemos un *dataset* integrado denominado `merged`. Para verificar el proceso se muestra el caso de Lehman Brothers, renombrado banco que tras su quiebra en 2008 fue expulsado del índice.

```
# Verificar los años en los que aparece LEHMQ en el dataset
lehman_years = merged[merged['ticker'] == 'LEHMQ']['year_x'].unique()
print("Años en los que aparece LEHMQ:", lehman_years)
```

```
Años en los que aparece LEHMQ: [1998. 1999. 2000. 2001. 2002. 2003. 2004.
2005. 2006. 2007. 2008.]
```

5.4. Creación de Variable Retorno

Mediante la obtención previa de `close_reb_adj` se ha obtenido el precio de cotización del último día de cotización de marzo. Hasta ahora los datos solo contienen información pasada, pero mediante esta variable se puede calcular el retorno futuro a los próximos 12 meses, es decir a la siguiente ventana de predicción. Esta variable de retorno futuro es denominada `target_12m_final`. El cálculo es relativamente sencillo ya que consisten en tomar el precio de la siguiente ventana ($t+1$) dividirlo entre el actual y restar 1 para obtener un valor decimal.

Sin embargo, surge una dificultad añadida. De nuevo, dada la naturaleza dinámica del S&P500 hay empresas que dejan el índice durante el periodo entre una ventana y otra. Esto supone que puede no haber un precio en la siguiente ventana por lo que el cálculo previo daría error. Tampoco sería correcto ignorar estas empresas ya que en el momento de rebalanceo no se sabía qué empresas saldrían del índice. En este trabajo se opta por usar los constituyentes presentes en el índice en cada momento como universo de inversión. Por ello, cuando una empresa sale del índice se calcula su retorno hasta la fecha de salida. Concretamente, se toma su precio de cotización de la tabla `prices.csv` más cercano a la fecha de salida en un intervalo máximo de 15 días anterior o posterior, para asegurar obtener un precio en el caso de que la cotización sea parada justo en la fecha de salida.

Para dichas empresas que experimentan una salida del índice en el año t , su retorno guardado en `target_12m_final` se calcula como: $(\text{close_exit} / \text{close_reb_adj}) - 1$

5.5. Limpieza

En primer lugar, se eliminan las columnas duplicadas y los índices residuales generados durante el proceso de integración de fuentes. Posteriormente, se realiza un análisis exploratorio preliminar con el objetivo de evaluar el grado de completitud del conjunto de datos.

El *dataset* inicial cuenta con 14,045 observaciones y 39 variables, correspondientes a 1,132 tickers únicos a lo largo de un periodo de 28 años.

Para visualizar gráficamente la distribución de valores faltantes, se utiliza la biblioteca `missingno` mediante la función `msno.matrix()`. Esta herramienta permite representar cada observación (combinación única de *ticker* y fecha) como una fila, y cada variable como una columna. La Figura 13 muestra dicho diagrama, facilitando la detección visual de patrones de ausencia de datos.




Figura 13: Diagrama de Valores Faltantes

Se observa que la mayoría de las variables presentan un alto grado de completitud. No obstante, destacan algunas excepciones:

- La variable `current_ratio` muestra un porcentaje elevado de valores faltantes (~21%).
- En la primera ventana temporal (marzo de 1998) no se dispone de datos fundamentales, lo cual es esperable dado que el año fiscal anterior (1997) aún no existe en la serie.
- Las variables de crecimiento interanual (`_yoy`) también presentan valores faltantes en los dos primeros años, ya que requieren información histórica previa para su cálculo.
- De forma similar, las variables de *momentum* (como retornos a 6 y 12 meses) no están disponibles en los primeros registros por no contar con precios pasados suficientes.
- Finalmente, la variable `target_12m_final` (retorno a 12 meses futuros) no contiene valores en la última ventana disponible (marzo de 2025), ya que los retornos hasta marzo de 2026 no se conocen aún en la fecha de elaboración de este trabajo.

Tratamiento:

A partir del análisis anterior, se establecen los siguientes criterios de depuración:

1. Eliminación de extremos temporales:

Se descartan todas las observaciones correspondientes a los años 1998 y 2025, dado su bajo nivel de completitud y falta de datos futuros o históricos necesarios.

2. Eliminación de columnas con alta proporción de nulos:

Se decide remover la variable `current_ratio`, debido a que más del 20% de sus registros son nulos, lo que compromete su utilidad y la calidad de imputación.

3. Filtrado por filas con alta cantidad de nulos

Se eliminan el reducido número de observaciones (<10) que presentan un porcentaje de valores faltantes superior al 70%, derivados bien de la unificación (en cuyo caso no es necesario imputar valores) o constituyentes de los que no se pudieron recuperar datos y por lo tanto su reconstrucción requeriría una imputación excesiva y poco fiable.

4. Imputación específica por tipo de variable:

- Para variables relacionadas con precios y volumen (por ejemplo: `max_1y`, `min_1y`, `volatility_1y`), se utiliza una propagación hacia adelante (*forward fill*), bajo el supuesto de continuidad de comportamiento técnico a corto plazo.
- Para variables de naturaleza fundamental, la imputación se realiza con el valor mediano de empresas del mismo tamaño (según variable *marketcap*), buscando preservar la coherencia estructural entre firmas comparables.

5.6. Descripción del dataset

Tras la limpieza y depuración del conjunto de datos, el número total de observaciones se ha reducido de 14,045 a 13,037. La Figura 14 muestra la distribución de los retornos futuros a 12 meses (`target_12m_final`) en forma de función de densidad suavizada.




Figura 14: Función de Densidad de Retornos a 12 meses

Se observa una distribución normal asimétrica con sesgo positivo. La mediana no está centrada en 0, sino que la mayoría de empresas tienden a ofrecer rendimientos bajos o moderados. La cola larga a la derecha indica la presencia de un número reducido pero significativo de empresas con rendimientos muy elevados. Son precisamente este tipo de rendimientos el objeto de identificación de los modelos. Esta distribución desequilibrada y sesgada dificulta el uso directo de modelos de regresión o clasificación con cortes arbitrarios. Por ello, en lugar de predecir directamente el retorno numérico o predecir clases con rangos fijos, se decide crear una variable categórica objetivo (`target_class`) dividiendo los retornos de cada año en quintiles, es decir, 5 grupos con igual número de observaciones. En la próxima sección, 5.7 Feature Engineering, se entra más en detalle sobre la creación de esta variable.

Con el objetivo de explorar relaciones lineales entre las variables numéricas del *dataset*, se ha calculado la matriz de correlaciones de Pearson, representada en la Figura 15 mediante un mapa de calor. Cada celda refleja el coeficiente de correlación entre un par de variables, variando entre -1 (correlación negativa perfecta) y +1 (correlación positiva perfecta), con valores cercanos a cero indicando independencia lineal.




Figura 15: Matriz de Correlaciones

Se puede identificar patrones esperables, como la alta correlación positiva entre variables relacionadas con el tamaño empresarial (*revenue*, *ebitda*, *ebit*, *netincome*, *marketcap*, *equity*). Lo que sugiere cierta redundancia informativa entre ellas. De igual forma, las variables técnicas derivadas del precio, como la volatilidad anual, el precio máximo y mínimo y las medias móviles, presentan correlaciones elevadas entre sí, al capturar aspectos similares del comportamiento bursátil. En contraste, la mayoría de las variables muestran una correlación baja con el retorno a 12 meses, lo cual es consistente con la literatura: en mercados financieros, las relaciones relevantes con la rentabilidad suelen ser no lineales y complejas. Esta observación refuerza la idoneidad de utilizar modelos como XGBoost o redes neuronales, capaces de capturar interacciones no evidentes entre los factores. Aunque no se ha realizado una eliminación directa de variables por colinealidad, este análisis proporciona información útil para futuras tareas de selección de variables y justifica la generación de indicadores más informativos como ratios o márgenes financieros.

5.7. Feature Engineering

Una vez consolidado y limpiado el *dataset*, se procede a la creación de nuevas variables adicionales no creadas hasta ahora. Este proceso de feature engineering se fundamenta en el Capítulo de 4. Selección de Variables y Proveedor. Las principales modificaciones han sido:

1. Normalización de la tasa libre de riesgo.

La variable `risk_free_rate` originalmente expresada en porcentaje se transforma a decimal para mantener su comparabilidad con otras variables decimales

2. Transformaciones logarítmicas con signo.

Se ha aplicado una transformación logarítmica a las variables fundamentales más relevantes (`revenue`, `ebitda`, `ebit`, `marketcap`, `equity`) mediante `signed_log`. La transformación estabiliza la varianza y reduce la influencia de valores extremos y permite conservar el signo original.

3. Ratios financieros clave

Se construyen indicadores clásicos de rentabilidad y eficiencia operativa, estas métricas si son comparables entre empresas de diferentes tamaños:

- `ebit_margin`
- `net_margin`
- `capex_to_revenue`
- `fcf_yield`

4. Múltiplos de Valoración

- `ps`: A parte de los múltiplos ya establecidos se añade precio sobre ventas (`ps`) para empresas de crecimiento alto donde los beneficios son negativos y otros múltiplos de valoración pueden no ser adecuados.

5. Relación retorno-riesgo

Para capturar retornos pasados ajustados a volatilidad, se definen nuevas variantes de las variables *momentum*: `ret_6m_vol` y `ret_12m_vol` dividiendo el retorno pasado para cada periodo entre la volatilidad media anual.

6. Diferencia de Medias:

Se incluye la variable `sma_diff` como diferencia entre las medias móviles a 1 y 2 años reflejando la tendencia reciente de precios.

7. Distancia a Máximos y Mínimos:

Se crean las variables `dist_max_1y` y `dist_min_1y` que miden la distancia relativa del precio actual respecto a sus extremos anuales.

8. Volatilidad relativa.

Una métrica no mencionada hasta ahora pero que puede resultar interesante consiste en dividir la volatilidad del último año (`volatility_1y`) entre la media móvil (`sma_1y`). Esto proporciona un coeficiente de variación financiera, que normaliza el “riesgo” por unidad de valor.

9. Tamaño

A partir de la capitalización bursátil (`marketcap`) se segmentan las empresas en 4 grupos: *Mega Cap*, *Large Cap*, *Mid Cap* y *Small Cap*, utilizando los percentiles 90%, 70% y 30%. Para facilitar su uso se codifican mediante variables *dummies*.

10. Variable Objetivo:

En línea con el análisis de la función de densidad de retornos en la sección 5.6 de Descripción del *dataset*, se procede a definir la variable objetivo del modelo. Para ello, se transforma la columna de retorno continuo a 12 meses (o hasta la fecha de exclusión para empresas que salen del índice) en una variable categórica de cinco clases, utilizando los quintiles de retorno como criterio de segmentación. Es decir, cada empresa se clasifica en función del quintil en el que se sitúa su rendimiento dentro del conjunto de empresas disponibles en ese mismo año. Esta aproximación resulta coherente desde el punto de vista inversor, ya que permite adaptar la evaluación del rendimiento al contexto de mercado: en años con rentabilidades generales bajas, incluso un retorno moderadamente negativo puede considerarse aceptable si supera al del conjunto del mercado. Así, el modelo no busca identificar un umbral fijo de rentabilidad, sino seleccionar sistemáticamente las empresas con mejor desempeño relativo en cada periodo.

Debido a que las clases son relativas a cada año, los umbrales de rentabilidad no son fijos. Para entender mejor cómo funcionan los umbrales de clase y observar la ciclicidad del mercado, la Figura 16 a continuación muestra los rangos de retorno futuro a 12 meses.




Figura 16: Rangos de Retorno futuro por Clase y Año

Finalmente se guarda de forma persistente el *dataset* denominado `data_base.csv`

5.8. Dataset Final

A continuación, se presenta las columnas finales de `data_base` usado en el entrenamiento de modelos:

Tabla 3: Variables de Dataset Base

Variable	Factor
ticker	Identificación
date	Identificación
target_12m_final	Objetivo
target_class	Objetivo
closeadj	Precio
ret_6m	Momentum
ret_12m	Momentum
ret_6m_vol	Momentum
ret_12m_vol	Momentum
sma_1y	Técnica
sma_2y	Técnica
sma_diff	Técnica
max_1y	Técnica
min_1y	Técnica
dist_max_1y	Técnica
dist_min_1y	Técnica
vol_1y	Liquidez
volatility_1y	Volatilidad
vol_over_sma	Volatilidad
revenue	Fundamental Pre-transformación

Desarrollo de estrategias de inversión mediante aprendizaje automático: análisis multifactorial y exploración de la eficiencia del mercado

ebitda	Fundamental Pre-transformación
ebit	Fundamental Pre-transformación
netinc	Fundamental Pre-transformación
eps	Fundamental Pre-transformación
equity	Fundamental Pre-transformación
capex	Fundamental Pre-transformación
ncfo	Fundamental Pre-transformación
fcfps	Fundamental Pre-transformación
signed_log_revenue	Fundamentales Transformadas
signed_log_ebitda	Fundamentales Transformadas
signed_log_ebit	Fundamentales Transformadas
signed_log_marketcap	Fundamentales Transformadas
signed_log_equity	Fundamentales Transformadas
roe	Quality
de	Quality
ebit_margin	Quality
net_margin	Quality
evebitda	Value
pb	Value
pe	Value
fcf_yield	Value
ps	Value
pe_yoy	Value
pb_yoy	Value
revenue_yoy	Growth
ebitda_yoy	Growth
ebit_yoy	Growth
eps_yoy	Growth
equity_yoy	Growth
fcfps_yoy	Growth
ncfo_yoy	Growth
capex_to_revenue	Esfuerzos de Inversión
capex_yoy	Esfuerzos de Inversión
marketcap	Tamaño
cap_Mega Cap	Tamaño (dummies)
cap_Large Cap	Tamaño (dummies)
cap_Mid Cap	Tamaño (dummies)
cap_Small Cap	Tamaño (dummies)
risk_free_rate	Macroeconómico

5.9. Conclusiones

En este Capítulo ha consolidado la base estructural del proyecto mediante la creación de un *dataset* completo, robusto y alineado con los objetivos del trabajo. A través de un proceso cuidadoso de recopilación, integración y transformación de datos financieros históricos, se ha logrado generar un conjunto de datos base que servirá como punto de partida para el entrenamiento y validación de modelos. Algunas decisiones metodológicas han sido especialmente relevantes, como priorizar la conservación de registros frente a su eliminación, dada la importancia crítica de cada observación en este tipo de análisis temporal y panel. Además, se han aplicado estrategias para minimizar la cantidad de datos faltantes sin comprometer la integridad del conjunto, asegurando que incluso las empresas que entran o salen del índice queden correctamente representadas. Otro aspecto destacable ha sido la decisión de mantener variables tanto en su forma original como transformada, permitiendo que los modelos (principalmente XGBoost y DNN por su capacidad no lineal) puedan capturar relaciones que escapen a una ingeniería de características explícita. En definitiva, se ha construido una base de datos sólida, trazable y alineada con buenas prácticas de ciencia de datos aplicada a finanzas, que permite abordar con garantías las fases posteriores de modelado y evaluación.

6. Entrenamiento y Validación de Modelos

6.1. Introducción

Tras la obtención de un conjunto de datos limpio y la construcción de las variables explicativas descritas en el capítulo 3. Selección de Variables y Proveedor, se procede al entrenamiento y evaluación de tres enfoques de modelado: Ridge Classifier, XGBoost y Redes Neuronales Profundas (DNNs). El modelo Ridge Classifier actúa como modelo base lineal, capaz de capturar relaciones proporcionales entre variables, y es ampliamente respaldado por la literatura debido a su simplicidad y poder de regularización. XGBoost se emplea como representante de los métodos basados en árboles de decisión, destacando por su rendimiento, capacidad de manejar no linealidades y su uso extensivo en tareas similares dentro del ámbito académico y profesional. Finalmente, se incorporan redes neuronales profundas, cuya capacidad de aprendizaje no lineal y representación jerárquica de patrones permite explorar relaciones complejas en los datos más allá de los límites de los modelos tradicionales.

Un aspecto extremadamente importante es la forma en la que se validan los datos. Dada la naturaleza de los datos en forma de panel, no sirve cualquier *split* tradicional. Como se ha comentado previamente un riesgo importante en el desarrollo de modelos es el *data leakage* que involucra entrenar con datos futuros ocasionando un sesgo en el modelo. En este trabajo se han implementado dos esquemas de validación temporal, uno para la búsqueda de hiperparámetros y otro para la evaluación con datos no vistos.

6.2. Esquema de Validación

Durante la fase de optimización de hiperparámetros, se utiliza una estrategia de validación conocida como *Expanding Window Validation* (también llamada *Growing Window* o *forward chaining cross-validation*). Esta técnica consiste en entrenar modelos sobre un conjunto acumulativo de años y validar siempre sobre el año siguiente en la secuencia temporal.

Como se puede observar en el esquema de la Figura 17, en cada iteración, la ventana de entrenamiento se expande para incluir toda la historia hasta ese momento, mientras que la validación se realiza sobre el siguiente año. Esto simula cómo se tomarían decisiones de inversión reales: usando toda la información histórica disponible hasta un cierto punto en el tiempo, sin violar la causalidad temporal. Para evitar sesgar el modelo se realiza la búsqueda de los mejores hiperparámetros únicamente sobre datos de entrenamiento, en concreto los primeros 4 años del *dataset* base (1999-2003).

El rendimiento del modelo se evalúa en cada *fold* a través de métrica de precisión sobre la clase de mayor retorno (clase 4), y el valor medio de esta métrica se utiliza para comparar combinaciones de hiperparámetros. Esta metodología es adecuada para evitar el sobreajuste a un año en particular y proporciona una visión más general del rendimiento interanual.




Figura 17: Esquema de Validación - Ventana Expansiva

6.3. Esquema de Evaluación

En cuanto al conjunto de Test, se hace uso de diferentes variantes en la literatura. El consenso establece que ventanas expansivas (la realizada en el patrón de validación) reflejan la visión de un inversor, permitiendo a los modelos entrenar con más datos y mejorar a medida que se producen los *folds*. Por otro lado, [24] hace uso de ventanas fijas, donde por cada *fold* se usa únicamente los n años previos a la evaluación, ya que se argumenta que los mercados son no estacionarios y que las relaciones entre variables cambian con el tiempo (regímenes de mercado, política monetaria, etc.). Sin embargo, tiene como limitación que el tamaño del conjunto de entrenamiento es menor, lo que puede dificultar el aprendizaje de relaciones complejas y aumentar la varianza del modelo. Durante la experimentación se probaron ambas aproximaciones (ventanas fijas y expansivas). Los resultados demostraron que las ventanas expansivas tienden a dar resultados superiores para todos los modelos tanto en la Precisión de la Clase 4 como en retorno.

El conjunto de Test empleado se muestra a continuación en la Figura 18. En una primera instancia cada modelo se entrena los primeros 4 años (1999-2003) y se realiza el Test sobre el año posterior (2004). Posteriormente, para cada *fold*, se expande el entrenamiento del *fold* anterior un año y se realiza el Test con datos *out-of-sample*, sobre la ventana siguiente ($train + 1$).




Figura 18: Esquema de Test - Ventana Expansiva

Sobre esta ventana de Test, se guardan las 20 empresas con mayor probabilidad de pertenecer a la Clase 4 y se calcula la media de sus retornos hasta la siguiente ventana de predicción (31/3/xx), simulando por tanto una cartera *equal-weight*, donde todas las posiciones tienen el mismo peso. De igual forma, se almacenan datos referentes a *Precision*, *Recall* sobre las predicciones de la Clase 4 y *Accuracy* sobre todas las clases. La elección de seleccionar 20 empresas por año responde al equilibrio entre diversificación y precisión predictiva.

Como se puede observar en el gráfico de la Figura 19, desde el punto de vista financiero, incluir más activos apenas reduce el riesgo específico adicional, ya que la mayoría del riesgo diversificable se elimina con unas 15-20 acciones. A nivel metodológico, centrarse en el Top 20 permite evaluar si el modelo es capaz de identificar con claridad las oportunidades más prometedoras, evitando diluir la señal al incorporar predicciones menos confiables.




Figura 19: Diversificación óptima

Fuente: Investopedia (2024)

6.4. Estandarización

La estandarización, también conocida como *z-score normalization*, consiste en transformar cada variable para que tenga media cero ($\mu=0$) y desviación estándar uno ($\sigma=1$). Esta operación es especialmente importante en modelos lineales regularizados, como Ridge, ya que permite que la regularización L2 (penalización sobre los coeficientes) actúe de forma equilibrada sobre todas las variables. Además, asegura que ninguna variable domine el proceso de ajuste por el mero hecho de tener una escala más grande. Por último, la estandarización mejora la convergencia numérica del modelo y estabiliza el entrenamiento.

Esta misma técnica de estandarización se ha aplicado también en el modelo de red neuronal profunda (DNN) desarrollado en este trabajo. Aunque las redes neuronales no dependen directamente de la magnitud de los coeficientes como los modelos lineales, la estandarización de los *features* mejora significativamente el proceso de entrenamiento: acelera la convergencia, evita que ciertas variables con escalas mayores interfieran desproporcionadamente en la activación de neuronas y contribuye a una mayor estabilidad en el cálculo del gradiente durante la retropropagación.

En concreto, para ambos modelos se aplicó la estandarización únicamente sobre el conjunto de entrenamiento mediante `StandardScaler`, utilizando el método `fit_transform()` sobre los datos de entrenamiento y posteriormente `transform()` sobre el conjunto de prueba. Este procedimiento evita la fuga de información, asegurando que las estadísticas empleadas para escalar los datos del Test no hayan sido influenciadas por su propio contenido.

En modelos basados en árboles como XGBoost la estandarización no es necesaria ya que estos algoritmos generan particiones del espacio de variables mediante la búsqueda de umbrales de decisión, y dichas particiones dependen únicamente del orden relativo de los datos, no de su magnitud. Esto significa que la escala numérica de los predictores no afecta al funcionamiento del modelo. De hecho, transformar los datos mediante estandarización o normalización puede distorsionar la distribución original y dificultar la identificación de puntos de corte óptimos. Por ello, en este trabajo, el modelo XGBoost fue entrenado directamente sobre las variables en su escala original, dejando que el modelo gestione internamente las diferentes magnitudes.

6.5. Construcción de Modelos

6.5.1. Ridge Classifier

En el caso de Ridge la validación de hiperparámetros se realiza únicamente para el parámetro α que en la literatura se conoce también como λ . Para cada valor de α (explorado en escala logarítmica de 10^{-3} a 10^3), se entrena el modelo Ridge y se evalúa su precisión para la clase 4, correspondiente a los activos con mayor retorno futuro (*outperformers*).

Finalmente, se selecciona el valor de $\alpha = 100$, que obtiene la mayor precisión media en estos cuatro *folds* temporales, equivalente a 0.2128.

El modelo se construye utilizando la clase `RidgeClassifier` de `scikit-learn`, con el parámetro de regularización $\alpha = 100$ previamente optimizado. Una vez entrenado con los datos escalados, se realizan predicciones sobre el conjunto de Test utilizando:

- `.predict()` para obtener la clase predicha.
- `.decision_function()` para obtener la puntuación continua asociada a cada clase, que se usa como base para seleccionar las mejores acciones.

Se probaron diversas combinaciones de variables, entre ellas los mejores resultados fueron obtenidos al eliminar las variables fundamentales pre-transformación como *revenue*, *eps*, *ebitda*, *netinc* y *fcfps* ya que estas variables dependen directamente del tamaño de la empresa (*revenue*, *ebitda*, *ebitda*), factor ya capturado en su capitalización bursátil o cantidad de acciones emitidas (*fcfps*, *eps*). Además, su capacidad predictiva ya ha sido capturada en la creación de nuevas variables de variación año sobre año. Estas variables no tienen una gran relación directa con los retornos y dado que Ridge no posee la capacidad de derivar relaciones complejas entre variables es aconsejable eliminarlas.

6.5.2. XGBoost

Para el modelo XGBoost la validación de hiperparámetros se realiza mediante una búsqueda aleatoria (*Random Search*) sobre un espacio definido por el siguiente conjunto de valores:

```
param_grid = {
    'max_depth': [3, 5, 7, 9],
    'learning_rate': logspace(-3, -1, 3),    # [0.001, 0.01, 0.1]
    'n_estimators': [100, 200, 400],
    'gamma': [0, 0.1, 1, 5],
    'min_child_weight': [1, 5, 10],
```

```

'reg_alpha': logspace(-2, 1, 4),          # [0.01, 0.1, 1, 10]
'reg_lambda': logspace(0, 2, 3),         # [1, 10, 100]
'subsample': [0.6, 0.8, 1.0],
'colsample_bytree': [0.6, 0.8, 1.0],
}

```

Random Search resulta especialmente útil en casos como éste donde los recursos computacionales son limitados y el espacio de posibles hiperparámetros es alto. En lugar de evaluar todas las combinaciones (más de 40.000), se selecciona un número fijo de configuraciones aleatorias a evaluar ($n_iter = 20$). Además, para ciertos parámetros cuyo valor puede oscilar en varias órdenes de magnitud, como `learning_rate`, `reg_alpha` y `reg_lambda` se prueba con valores en escala logarítmica.

Tras la validación se obtiene un conjunto de mejores hiperparámetros que maximizan la precisión media para todos los *folds* de validación sobre la Clase 4, equivalente a 0.2518

```

best_params = {
    'max_depth': 9,
    'learning_rate': 0.001,
    'n_estimators': 100,
    'gamma': 1,
    'min_child_weight': 1,
    'reg_alpha': 10.0,
    'reg_lambda': 100.0,
    'subsample': 0.6,
    'colsample_bytree': 1.0,
    'objective': 'multi:softprob',
    'eval_metric': 'mlogloss',
    'num_class': 5,
    'use_label_encoder': False,
    'random_state': 42
}

```

El modelo XGBoost se entrena con estos hiperparámetros óptimos. De nuevo se implementó un esquema con ventana expansiva al ofrecer mejores resultados que con ventana fija. En este caso los mejores resultados fueron obtenidos al incluir todas las variables del *dataset* base, tanto Fundamentales pre-transformación como las nuevas variables generadas.

6.5.3. DNN

El modelo de redes neuronales se valida de forma similar a XGBoost mediante el uso de una búsqueda aleatoria sobre los mejores parámetros, utilizando la librería Keras Tuner. De nuevo, se sigue la lógica de *cross-validation* con ventana expansiva. Los hiperparámetros ajustados incluyen:

- **Número de capas ocultas** (`num_layers`): Se exploran entre 1 y 3 capas
- **Número de unidades por capa** (`units_i`): Cada capa puede tener entre 64 y 256 neuronas en pasos de 64 neuronas.
- **Tasa de dropout** (`dropout`): Representa la fracción de neuronas desconectadas aleatoriamente durante el entrenamiento. Esto tiene como objetivo evitar que el modelo dependa demasiado de ciertas neuronas, lo que ayuda a prevenir *overfitting*.
- **Tasa de aprendizaje** (`lr`): De nuevo explorado en escala logarítmica para valores entre 10^{-4} a 10^{-2} , permitiendo ajustes finos en la tasa de aprendizaje.

Mediante el ajuste de `max_trials = 15` y `executions_per_trial = 1`, se fija el número de comprobaciones a 15 para limitar el tiempo de ejecución. Inicialmente se experimentó con un mayor número de búsquedas (`max_trials = 20`) por mantener comparabilidad con XGBoost, sin embargo los resultados demostraron sobreajuste y un tiempo de ejecución demasiado elevado.

Una dificultad añadida fue asegurar que el objetivo a optimizar sea la precisión de la clase 4. Por defecto Keras Tuner optimiza el *Accuracy* durante la validación, indicando que se seleccionaría el modelo con mejor precisión global (*accuracy* sobre las 5 clases). Para asegurar la comparabilidad con los otros modelos, se ejecuta la búsqueda con `val_accuracy` como métrica guía y posteriormente para cada modelo resultante se calcula `precision_score` solo para la clase 4. Finalmente, antes de entrenar el modelo se selecciona el conjunto de hiperparámetros que maximiza la precisión de clase 4.

Adicionalmente, durante la experimentación se observó que el rendimiento del modelo así como su precisión variaban significativamente según las variables que se incluyeran. Dado que los resultados incluyendo todas las variables de `data_base` no eran excepcionales, se decidió simplificar la cantidad de variables de alguna forma. El criterio elegido consiste en aplicar una técnica de selección automática de características supervisada. Concretamente, se utilizó `SelectKBest` con la función `f_classif`, que selecciona las variables más informativas en función de su correlación estadística con la variable objetivo. Esta técnica permite reducir el número de variables a un subconjunto de las 30 más relevantes. Gracias a esto se reduce el ruido introducido por variables menos relevantes, se acelera el entrenamiento del modelo y se favorece la generalización. Mediante esta técnica se obtuvieron resultados de retorno medio anual del 15.62%. Posteriormente se probó excluir únicamente variables como el precio de cotización en la fecha de rebalanceo, el máximo, mínimo de cotización y la capitalización de mercado. Se incluyeron el resto de las variables (excepto las de identificación: `date` y `ticker`), incluso las fundamentales sin transformar, ya que las redes neuronales son capaces de aprender combinaciones no lineales entre ellas, identificando patrones no obvios. Éste último

método sorprendentemente obtuvo el mejor resultado para DNN tanto en términos de precisión como de retorno anual acumulado (16.79%).

Los mejores resultados obtenidos durante la validación consiguieron una Precisión de clase 4 equivalente a 0.347. En concreto, los parámetros escogidos por la búsqueda aleatoria fueron:

- 1 capa oculta.
- 192 neuronas en la capa oculta.
- *Dropout* del 30%.
- *Learning rate* (lr) de 0.00595, relativamente alto que permite una convergencia rápida sin inestabilidad aparente.

En resumen, se observa que Tuner elige una arquitectura sencilla y moderadamente pequeña.

7. Evaluación de Modelos

7.1. Introducción

En este capítulo se exponen los resultados comparativos entre los tres modelos explorados. Tras su construcción se han guardado las métricas expuestas en la Sección 2.8 “Métricas de Evaluación”. Posteriormente se realiza un análisis sobre las carteras generadas por los modelos, emitiendo una valoración, puntos a destacar y reflexión.

Primero, se debe definir qué retornos implica batir al mercado. Aunque este tema se ha abordado parcialmente de forma anterior, no se puntualizó entre retornos con dividendos o sin dividendos durante el mismo periodo de tiempo al Test. Dado que los modelos trabajan con precios ajustados, esto incluye el retorno con dividendos. Para calcular el retorno del S&P500 con dividendos, hay dos alternativas:

- Calcular retornos en base a nuestro *dataset* para una cartera compuesta por los 500 constituyentes. Este aproximamiento se realiza ponderando los retornos a 12 meses (`target_12m_final`) de cada empresa por su capitalización de mercado (ya que en el S&P500 no todas las empresas tienen el mismo peso). El retorno del S&P500 cada año sería pues una media ponderada de los retornos de las 500 empresas presentes en cada ventana. El retorno acumulado, definido en la Ecuación (10) de la Sección 2.8 Métricas de Evaluación, permite averiguar cómo se comporta una estrategia a lo largo del tiempo, derivando así que rentabilidad total podría suponer haber invertido en el índice. Este aproximamiento obtiene un retorno acumulado de 7,66 (666%) en Marzo de 2025. Esto implica que 1€ invertido en Marzo de 2004 tendría un valor de 7,66€ en Marzo de 2025.
- La otra alternativa es tomar los retornos “oficiales” del S&P500 durante la misma ventana temporal al Test. Desde LSEG se recupera un retorno acumulado de 7,32 (632%).

Dado que ambas consideraciones son prácticamente similares, y con el fin de representar una visión conservadora se toma el mejor resultado, un retorno acumulado de 7,66. Así pues, las carteras serán comparadas con una versión propia del índice S&P500 derivada en base al conjunto de datos desarrollado previamente. La similitud de ambos retornos valida parcialmente que el *dataset* ha sido construido de forma correcta.

7.2. Evaluación de Clasificadores

El *Accuracy* medido osciló tanto entre modelos, como temporalmente. La Figura 20 muestra como los tres modelos se mueven generalmente en el mismo rango de *Accuracy*, oscilando alrededor del 20-26%, ligeramente mejor que un clasificador arbitrario (20%), lo que refleja la dificultad del problema. XGBoost destaca en ciertos años como 2013 y 2021 donde alcanza picos superiores al 28%. Ridge y DNN parecen sufrir en años donde los rangos de retornos varían bruscamente, como en 2008. Sin embargo, DNN parece beneficiarse de un entrenamiento amplio y al mejorar con el segundo año de crisis del *dataset*, donde obtiene el mejor resultado de *Accuracy*.




Figura 20: Accuracy por Año (ventana de predicción)

De forma similar, la Figura 21 muestra la evolución de la precisión sobre la clase 4. En concreto se muestra la precisión para los doce meses posteriores a la ventana indicada de predicción. XGBoost destaca en varios años con valores de precisión notablemente superiores, en particular en 2016 y 2020, donde alcanza el 50%. Ridge presenta una trayectoria similar, aunque con peor desempeño. El modelo de DNN presenta un comportamiento estable, con años difíciles como 2008 o 2011. En general la medida de precisión es altamente dependiente de los retornos de mercado. Si bien las clases están fijadas para estar equilibradas, a los modelos les cuesta predecir en qué rangos de retornos se moverá el mercado en el próximo año y por tanto se producen dichos picos y valles de precisión de forma conjunta entre modelos. Aunque 20-40% puedan parecer rangos bajos de precisión, basta con identificar ligeramente una mayor cantidad de empresas extraordinarias que las que se identificarían puramente al azar (20%) para tener un buen resultado.




Figura 21: Precisión por Año (Ventana de Predicción)

En la siguiente página (Figuras 22, 23 y 24) se muestran las matrices de confusión de forma agregada para cada modelo. Estas matrices permiten analizar las decisiones agregadas de clasificación por cada modelo para todo el conjunto de Test. Como se mencionó previamente las clases hacen referencia a quintiles de retornos a 12 meses, por lo que sus rangos varían por año, tal y como se observaba en la Figura 16 de la Sección 2.7 “Feature Engineering”. Sin embargo, con el objetivo de que el lector se haga mejor idea de qué tipo de empresa representa cada clase, a continuación, se proporcionan los rangos medios para todo el conjunto de evaluación:

- Clase 0: [-97.65%, -15.18%]
- Clase 1: [-15.18%, -2.13%]
- Clase 2: [+2.13%, +16.38%]
- Clase 3: [+16.38%, +35.73%]
- Clase 4: [+35.73%, +865.26%]

En primer lugar, se observa que los tres modelos muestran cierto desempeño en identificar la clase 0. Esto sugiere que los modelos son eficaces encontrando las empresas que probablemente tendrán rendimientos negativos o muy bajos. Esto reduce significativamente el riesgo de pérdidas severas, permitiendo partir de una mejor posición sobre la que construir carteras. Además, existe un solapamiento significativo entre estas clases. Dado que muchas empresas tienen rendimientos moderados, los modelos tienden a confundirlas entre sí, lo cual es comprensible desde un punto de vista estadístico.

El modelo de regresión Ridge mostró un comportamiento conservador a lo largo de la clasificación. En concreto, se evidencia que la clase 4 es clasificada incorrectamente en muchos casos como clase 1 o clase 2. Esta dispersión implica que el modelo tiene dificultades para distinguir de forma consistente el *outperformance*, y que las características que identifican empresas con rendimientos altos no son completamente lineales. En consecuencia, aunque Ridge puede evitar pérdidas, también limita su exposición a oportunidades altamente rentables, lo que se traduce en una menor rentabilidad agregada en comparación con otros enfoques más agresivos.

XGBoost presenta una mejora en la identificación de empresas del quintil superior (clase 4). Este modelo parece evitar activamente la clase 2, asignando muchas observaciones que corresponden a ella hacia clases adyacentes como la 1 o la 3. Esta conducta puede deberse a que la clase 2 no presenta patrones suficientemente distintivos, y el modelo, al estar entrenado para minimizar una métrica de pérdida global como `mlogloss`, prioriza predicciones más confiables en clases con mejor separabilidad.

DNN demuestra una capacidad destacada para identificar correctamente observaciones pertenecientes a la clase 4. Aunque la precisión media de XGBoost resulta superior en términos estrictos, es importante señalar que DNN clasifica un número significativo de empresas de clase 3 como clase 4, las cuales, si bien no alcanzan el quintil superior, presentan rendimientos por encima de la media. Esto contribuye positivamente a los retornos acumulados obtenidos por el modelo, ya que dichas empresas también representan oportunidades atractivas de inversión. No obstante, esta estrategia más ambiciosa viene acompañada de clasificar incorrectamente como etiqueta 4, empresas de clase 0 y 1. El hecho de que DNN tiende a realizar más predicciones hacia la clase 4, en comparación con XGBoost y Ridge, explica en parte su mayor estabilidad en la métrica de precisión.




Figura 22: Matriz de Confusión - Ridge




Figura 24: Matriz de Confusión - XGBoost




Figura 23: Matriz de Confusión - DNN

7.3. Evaluación de Carteras

En esta sección, se completa el análisis de los clasificadores con el análisis de los retornos generados por las carteras compuestas por los modelos. Todas las carteras son compuestas por las 20 empresas con mayor probabilidad de pertenecer a Clase 4, por lo que, si bien la precisión del clasificador para la clase 4 revisada en la Sección previa (7.1 Desempeño de Clasificadores) tiene un gran impacto en los retornos generados, también lo tiene que las empresas falsamente predichas como clase 4, sean de la clase más alta posible. La Figura 25 muestra la evolución de 1€ invertido en marzo de 2004, hasta marzo de 2025. Sorprendentemente todos los modelos consiguen un retorno mejor al del *benchmark*.




Figura 25: Retorno Acumulado por Modelo vs. S&P500

Resulta interesante que a pesar de que DNN obtiene la peor precisión, obtiene el mejor retorno acumulado. Esto se debe a dos motivos:

- DNN no obtiene la mejor precisión, pero incluye gran número de empresas de clase 3, que poseen también rentabilidades altas
- Si se observa la precisión sobre las 20 empresas seleccionadas en la Tabla 4, en lugar de sobre el total de predicciones de clase 4, DNN y XGBoost se encuentra prácticamente en igualdad. Esto se puede observar en la columna de “Precision Top 20” de la Tabla 4.

La Tabla 4 también muestra rendimientos acumulados medios (CAGR*), así como otras métricas relevantes. Se observa que la volatilidad de las carteras es más del doble que la del índice. Consecuentemente, los modelos sufren en mayor medida en años de recesión como 2008, al estar menos diversificados y expuestos a acciones más volátiles.

Tabla 4: Comparación de Carteras

Modelo	CAGR (%)	Volatilidad	Peor año	MDD* (%)	Accuracy medio	Precision_4 media	Precision Top 20	Recall_4 medio
Ridge	13.58	0.5361	2008	-48.87	0.226	0.229	0.255	0.103
XGBoost	14.87	0.4179	2008	-43.08	0.240	0.307	0.283	0.170
DNN	16.79	0.5768	2008	-40.70	0.227	0.221	0.274	0.183
S&P 500	10.18	0.1956	2008	-36.49	0.200	0.200	0.200	-

Dividendo el retorno medio anual entre la volatilidad, se obtiene una medida similar al *Sharpe-Ratio* (asumiendo una tasa libre de riesgo igual a cero para todos los modelos con fines comparativos). En la Tabla 5 se observa que, a pesar de la existencia de *outperformance* en términos absolutos (sin ajustar por riesgo), la medida de retorno ajustada es menor a la del S&P500, debido al incremento sustancial de volatilidad.

Tabla 5: Retornos ajustados y Outperformance

Modelo	CAGR / Volatilidad	Outperformance (%)
Ridge Classifier	0,253	3,399
XGBoost	0,356	4,689
DNN	0,291	6,617
S&P 500	0,520	0,000

DNN se remarca como el modelo con mejor retorno medio anual (16.79%), sobrepasando al retorno medio del S&P500 en un 6.617% anual. Tales diferencias de rentabilidad tienen un efecto compuesto a lo largo del tiempo, resaltado en la diferencia de retorno acumulado de la Figura 25. Este descubrimiento pone de manifiesto la gran oportunidad que el uso de técnicas de aprendizaje automático puede suponer en mercados capitales y para aquellos inversores dispuestos a aprender y dominar su uso.

7.4. Conclusiones de Evaluación

Los resultados muestran que todos los modelos evaluados superan sistemáticamente el rendimiento del índice S&P 500, lo que valida parcialmente el enfoque. En particular, el modelo de redes neuronales profundas (DNN) destaca con el mayor retorno anual compuesto (16.79%), pero también con la mayor exposición al riesgo, reflejada en una volatilidad del 57.68%.

Los tres modelos muestran un rendimiento modesto pero significativo en términos de métricas de clasificación. A pesar de la moderada mejora frente a un clasificador aleatorio, cuando se construyen carteras seleccionando únicamente las 20 empresas con mayor probabilidad de pertenecer a la clase 4, la precisión mejora sustancialmente para los modelos (excepto XGBoost que decrece ligeramente), lo que indica que incluso una ligera ventaja en predicción puede generar carteras significativamente superiores al *benchmark*.

El modelo XGBoost presenta el mejor equilibrio entre rentabilidad y riesgo (excluyendo el índice), siendo el más estable y con menor volatilidad relativa. DNN, por su parte, muestra mayor ambición al identificar de forma absoluta más empresas de clase 4. Este hecho también proporciona mayor probabilidad de encontrar empresas en el percentil 95% que disparan la rentabilidad de la cartera. Aunque esto conlleva a un mayor número de falsos positivos en clase 4, incluyendo empresas que en realidad pertenecen a clases 0 y 1. En última instancia, el impacto neto en los retornos es positivo, al capturar también muchas empresas de clase 3 que ofrecen retornos altos.

Además, cabe señalar que todos los modelos muestran cierta capacidad para evitar empresas de muy bajo rendimiento (clase 0). Esta propiedad, a menudo subestimada, tiene un impacto importante en la construcción de carteras, ya que excluir consistentemente los activos con mayor probabilidad de pérdida puede ser tan valioso como acertar en los mayores ganadores. Esto refuerza el interés por estrategias basadas en la eliminación de “perdedores” como enfoque alternativo o complementario.

También se observa que los modelos tienden a sobreestimar las clases bajas, posiblemente debido a que las crisis financieras (como la de 2008) introducen retornos muy negativos, mientras que años similares sin crisis no permiten al modelo distinguirlos. Esto pone de manifiesto lo difícil que resulta anticipar recesiones, incluso con variables más adecuadas para ello (como indicadores adelantados), no utilizados en este trabajo.

Por otro lado, aunque Ridge es el modelo con menor precisión global sobre la clase 4, su precisión (al igual que DNN) mejora significativamente al centrarse en las 20 empresas seleccionadas, lo que sugiere que estos modelos se benefician de la selección particular de 20 empresas y distribuyen probabilidades de forma correcta. Asimismo, se confirma que incluso modelos lineales como Ridge pueden capturar relaciones relevantes, especialmente cuando se combinan con una buena ingeniería de variables y selección cuidadosa del universo de inversión

8. Conclusiones

8.1. Reflexiones Finales

El presente Trabajo Fin de Grado ha cumplido satisfactoriamente con los dos objetivos generales establecidos al inicio del proyecto:

- Por un lado (**OG-1**), se ha realizado una revisión teórica rigurosa de la literatura financiera y de inversión cuantitativa, a partir de la cual se han identificado y construido variables clave con capacidad predictiva sobre el retorno futuro de acciones.
- Por otro lado (**OG-2**), se ha logrado desarrollar y evaluar técnicamente varios modelos de aprendizaje automático supervisado Ridge Classifier, XGBoost y redes neuronales profundas capaces de clasificar acciones según su probabilidad de *outperformance*, es decir, de superar el rendimiento del índice S&P500.

Además, se han alcanzado de forma completa los objetivos específicos planteados, que abarcan desde la contextualización del papel del inversor, hasta la implementación de un *pipeline* de machine learning en Python y el análisis de resultados financieros y predictivos. Se han diseñado y evaluado estrategias de inversión sistemáticas, y se ha demostrado que todos los modelos analizados han generado rentabilidades superiores al *benchmark* durante un amplio espacio temporal (31/3/2004 - 31/3/2025), evidenciando que las técnicas de ML aplicadas de forma rigurosa pueden aportar valor en la gestión de carteras. Sin embargo, estos mejores resultados vienen acompañados de una mayor volatilidad, y ninguno de los modelos bate al S&P500 en la métrica de *Sharpe-Ratio* (asumiendo una tasa libre de riesgo igual a cero).

Durante el desarrollo del trabajo, se han presentado distintos retos. Uno de los principales ha sido la extracción de información bruta. Se empleó un tiempo extenso en decidir y extraer el proveedor que permitiese construir un modelo robusto. Además, la correcta estructuración del *dataset* histórico en formato panel implicó una dificultad añadida y un desarrollo lento e iterativo, dada la variabilidad de los constituyentes del índice a lo largo del tiempo.

Otro reto relevante ha sido diseñar esquemas de validación temporal que evitasen el *data leakage*, ya que un tratamiento inadecuado de la información temporal hubiera invalidado los resultados. Ambos problemas fueron solucionados mediante técnicas como ventanas expansivas y estrategias de separación temporal estricta entre entrenamiento y test.

También se cometieron errores en etapas iniciales, como realizar una estandarización propia sin el uso de librerías como *Standard Scaler* o aplicar estandarización global sin

separar entrenamiento y test, lo que fue corregido tras identificar el problema en la validación cruzada. Estos errores han permitido reforzar la comprensión sobre las buenas prácticas en proyectos de ciencia de datos y reforzar la importancia de la trazabilidad de los datos.

Desde el punto de vista del aprendizaje, este trabajo ha requerido la adquisición de nuevos conocimientos no tratados en profundidad durante el Doble Grado de Ingeniería Informática y Administración y Dirección de Empresas, como el uso de librerías avanzadas de ML (XGBoost, Keras Tuner), validación con paneles temporales, teoría de factores y evaluación financiera de modelos predictivos. La integración de conocimientos de finanzas, programación, y ciencia de datos ha sido fundamental para resolver el problema propuesto, demostrando la capacidad de aplicar de forma práctica y transversal lo aprendido en el grado.

Este proyecto ha sido especialmente enriquecedor tanto a nivel profesional como personal. Profesionalmente, me ha permitido consolidar habilidades clave como la programación en Python, la gestión de datos financieros reales, la comprensión y aplicación de modelos predictivos, y la capacidad de analizar resultados desde una perspectiva tanto técnica como estratégica. A nivel personal, ha reforzado mi capacidad de organización, disciplina y resolución autónoma de problemas, especialmente al afrontar tecnologías y metodologías no tratadas explícitamente en el plan de estudios.

8.2. Implicaciones sobre la Eficiencia de Mercado

Aunque no ha sido el objetivo central de este trabajo, la cuestión de la eficiencia de los mercados ha sido inevitablemente tratada de forma tangencial. En línea con la literatura sobre *asset pricing* y los estudios de factores, los resultados obtenidos sugieren que la eficiencia no debe entenderse como un estado absoluto, sino más bien como un continuo con distintos grados. Los mercados tienden a ajustarse en función del comportamiento agregado de los participantes, pero dicho ajuste no es instantáneo ni perfecto. Los modelos propuestos en este trabajo, si bien logran generar carteras con rendimientos absolutos superiores al promedio del mercado, no consiguen ratios de Sharpe superiores. No obstante, también se han señalado las limitaciones de dicha métrica, ya que no todos los agentes aceptan la volatilidad como una medida directa del riesgo. Además, es importante reconocer otras limitaciones: el rendimiento pasado no garantiza su replicabilidad futura, y la eficiencia puede depender del horizonte temporal, del universo de activos considerado y de la viabilidad real de ejecutar las estrategias. En este sentido, los resultados invitan a una visión matizada: los mercados no son completamente eficientes, pero tampoco completamente ineficientes.

8.3. Trabajos Futuros

Este trabajo ha pretendido ofrecer un marco flexible que pueda ser ampliado en varias direcciones. En primer lugar, sería de gran interés aplicar los modelos desarrollados a otros mercados internacionales, como el CSI 300 (China) o el FTSE 100 (Reino Unido), para comprobar si las relaciones encontradas son consistentes en diferentes contextos económicos, estructurales y regulatorios. Por otro lado, se podría enriquecer el conjunto de variables incorporando factores relacionados con la información privilegiada (*insider trading*), como la compra activa de acciones por parte de la directiva o la permanencia de los fundadores en el equipo gestor. Estas señales, no siempre reflejadas en los fundamentales tradicionales, pueden aportar valor predictivo adicional sobre el comportamiento futuro de la acción. Asimismo, sería interesante experimentar con distintas ventanas temporales de predicción (por ejemplo, horizontes a 6 o 24 meses), así como con nuevas combinaciones de variables o interacciones no lineales. Otra línea prometedora es la incorporación de datos alternativos como sentimiento en redes sociales, cobertura en prensa financiera o datos satelitales, que pueden capturar información anticipada no recogida en las métricas financieras convencionales. Por último, el desarrollo de algoritmos solo es el comienzo de la tarea. Su puesta en práctica y ejecución con carteras que gestionen fondos reales es otro reto de igual interés y envergadura. En definitiva, el marco planteado puede evolucionar hacia modelos más robustos, generalizables y sensibles a la complejidad del entorno financiero real, abriendo así nuevas oportunidades para la investigación aplicada y el desarrollo de estrategias cuantitativas.

8.4. Relación del Trabajo con los Estudios Cursados

En cuanto a la relación con los estudios cursados, el trabajo es coherente con la formación adquirida en materias de estadística, econometría, matemáticas financieras, programación, bases de datos y fundamentos de inversión. Sin embargo, también ha requerido ampliar significativamente esos conocimientos, lo cual demuestra la capacidad de aprendizaje continuo y de adaptación a tecnologías de vanguardia, como se espera de un perfil profesional en ciencia de datos aplicada a finanzas.

Por último, este trabajo ha supuesto la aplicación de competencias transversales fundamentales tratadas durante los estudios, tales como:

- **Innovación y Creatividad:** para desarrollar modelos y evaluar resultados.
- **Comunicación Efectiva:** para explicar procesos técnicos complejos.

Así como otras más generales, relacionadas con la planificación personal, disciplina y capacidad de aprendizaje autónomo:

- **Gestión del tiempo y planificación:** por la naturaleza iterativa del proceso.
- **Capacidad de aprendizaje autónomo:** especialmente en tecnologías nuevas.

En resumen, el TFG ha permitido demostrar no solo la adquisición de conocimientos técnicos y financieros, sino también la capacidad de integrarlos en un proyecto complejo, con impacto potencial en la toma de decisiones reales en el ámbito de la inversión cuantitativa.

9. Bibliografía

- [1] K. C. M. Szikszai, «MSCI,» 2024. [En línea]. Available: <https://www.msci.com/www/blog-posts/sizing-up-the-global-market/05073690405>. [Último acceso: 2025].
- [2] A. Ganti, «Investopedia,» 2025. [En línea]. Available: <https://www.investopedia.com/terms/a/assetclasses.asp>. [Último acceso: 2025].
- [3] M. Jackson, «Yahoo Finance,» 2024. [En línea]. Available: <https://finance.yahoo.com/news/global-real-estate-valued-379-180013773.html>. [Último acceso: 2025].
- [4] A. Damodaran, «NYU Stern School of Business,» 2024. [En línea]. Available: https://pages.stern.nyu.edu/~adamodar/New_Home_Page/datafile/histretSP.html. [Último acceso: 2025].
- [5] T. Mitchel, «Machine Learning,» New York, McGraw-Hill, 1997.
- [6] A. L. Samuel, «Some studies in machine learning using the game of checkers,» *IBM Journal of Research and Development*, 1959.
- [7] Zuckerman, *The Man Who Solved the Market*, 2019.
- [8] Ferri, *The power of passive investing: More wealth with less work*, John Wiley & Sons, 2017.
- [9] M. C. Jensen, «The Performance of Mutual Funds in the Period 1945–1964,» *The Journal of Finance*, vol. 23, pp. 389-416, 1968.
- [10] S&P Down Jones Indices, «SPIVA U.S Scorecard Year-End 2023,» S&P Global, New York, 2023.
- [11] Profiles Software, «AI & Machine Learning in Portfolio Management,» Profiles Software, 2023.
- [12] E. F. Fama, «Efficient Capital Markets: A Review of Theory and Empirical Work,» *The Journal of Finance*, vol. 25, n° Wiley for the American Finance Association, 1970.
- [13] W. F. Sharpe, «Capital Asset Prices: A Theory of Market Equilibrium under Conditions of Risk,» *The Journal of Finance*, vol. 19, 1964.
- [14] J. Linter, «The Valuation of Risk Assets and the Selection of Risky Investments in Stock Portfolios and Capital Budgets,» *The Review of Economics and Statistics*, vol. 47, 1965.
- [15] J. Mossin, «Equilibrium in a Capital Asset Market,» *Econometrica*, vol. 34, 1966.
- [16] W. F. Sharpe, «Mutual Fund Performance,» *The Journal of Business*, vol. 39, 1966.

- [17] K. F. E. Fama, «The Cross-Section of Expected Stock Returns,» *The Journal of Finance*, vol. 47, pp. 427-465, 1992.
- [18] K. F. E. Fama, «Common Risk Factors in the Returns on Stocks and Bonds,» *Journal of Financial Economics*, vol. 33, pp. 3-56, 1993.
- [19] M. Carhart, «On Persistence in Mutual Fund Performance,» *The Journal of Finance*, vol. 52, pp. 57-82, 1997.
- [20] K. F. E. Fama, «A Five-Factor Asset Pricing Model,» *Journal of Financial Economics*, vol. 116, p. 1-22, 2015.
- [21] C. X. L. Z. K. Hou, «Digesting Anomalies: An Investment Approach,» *The Review of Financial Studies*, vol. 28, p. 650-705, 2015.
- [22] B. K. D. X. S. Gu, «Empirical Asset Pricing via Machine Learning,» *The Review of Financial Studies*, vol. 33, 2020.
- [23] F. P. Asness, «Quality minus junk,» *Review of Accounting Studies*, 2014.
- [24] S. G. M. & L. X. Rodríguez, «Outperformance of stocks using machine learning: Evidence from the S&P 500,» *Journal of Economic Behavior & Organization*, vol. 221, 2024.
- [25] H. Marks, *The Most Important Thing: Uncommon Sense for the Thoughtful Investor*, New York: Columbia University Press, 2011.
- [26] P. Llobregat, *Estrategias de creación de carteras de inversión basadas en ciencia de datos*, Valencia, 2024.
- [27] M. Modigliani, «The Cost of Capital, Corporation Finance and the Theory of Investment,» *The American Economic Review*, vol. 48, 1958.
- [28] C. Zook y N. Furr, «Founder-Led Companies Outperform the Rest- Here's Why,» *Harvard Business Review*, 2016.
- [29] D. Burgstahler y I. Dichev, «Earnings management to avoid earnings decreases and losses,» *Journal of Accounting and Economics*, vol. 24, 1997.
- [30] N. Jegadeesh y S. Titman, «Returns to buying winners and selling losers: Implications for stock market efficiency,» *The Journal of Finance*, vol. 48, 1993.
- [31] T. George y C.-Y. Hwang, «The 52-week high and momentum investing,» *The Journal of Finance*, vol. 59, 2004.
- [32] I. Muñoz Felder, *TFG code*, 2025. [Online]: <https://github.com/igmun/tfg-code>

10. Anexo

OBJETIVOS DE DESARROLLO SOSTENIBLE



Grado de relación del trabajo con los Objetivos de Desarrollo Sostenible (ODS).

Objetivos de Desarrollo Sostenibles	Alto	Medio	Bajo	No Procede
ODS 1. Fin de la pobreza.	X			
ODS 2. Hambre cero.			X	
ODS 3. Salud y bienestar.			X	
ODS 4. Educación de calidad.	X			
ODS 5. Igualdad de género.				X
ODS 6. Agua limpia y saneamiento.				X
ODS 7. Energía asequible y no contaminante.				X
ODS 8. Trabajo decente y crecimiento económico.	X			
ODS 9. Industria, innovación e infraestructuras.		X		
ODS 10. Reducción de las desigualdades.		X		
ODS 11. Ciudades y comunidades sostenibles.				X
ODS 12. Producción y consumo responsables.				X
ODS 13. Acción por el clima.				X
ODS 14. Vida submarina.				X
ODS 15. Vida de ecosistemas terrestres.				X
ODS 16. Paz, justicia e instituciones sólidas.			X	
ODS 17. Alianzas para lograr objetivos.				X

Nota: La vinculación con los de ODS de mayor relación (ODS1, ODS4 y ODS8) se ha redactado en la Sección 1.4 Impacto Esperado.